115-1 TAICA《生成式 AI：文字與圖像生成的原理與實務》

05 AI 怎麼記得前面說過什麼？

RNN、Attention 與 Transformer

政治大學應用數學系 蔡炎龍

01.

RNN 的原理

遞歸層原理

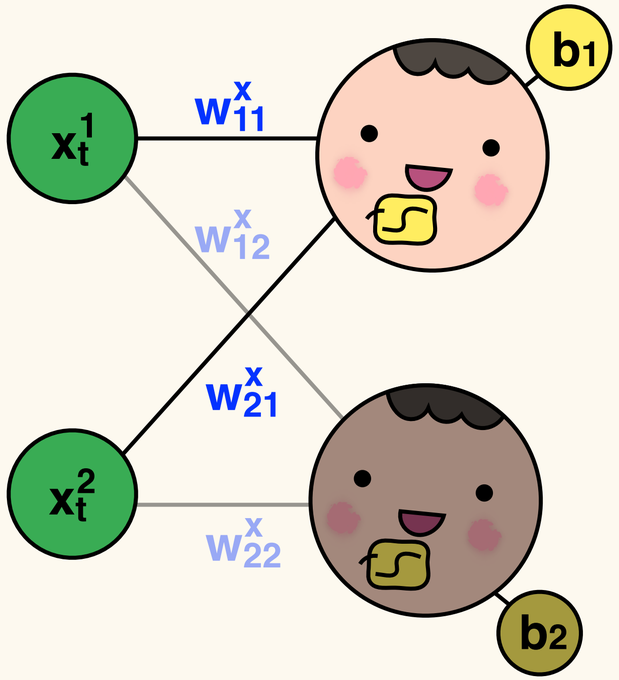

RNN 層

我們用有兩個輸入, 兩個 RNN 神經元的遞歸層來說明 (我們專注在第一個 RNN 神經元)。

看起來好像和以前全連結層一樣...

遞歸層原理

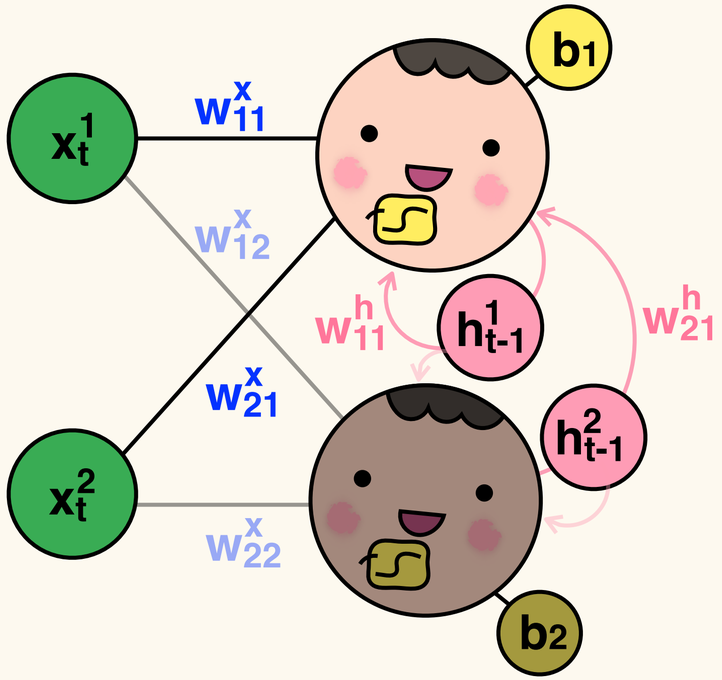

RNN 層

不一樣的是上次 RNN 層的輸出還會再傳回來。

遞歸層原理

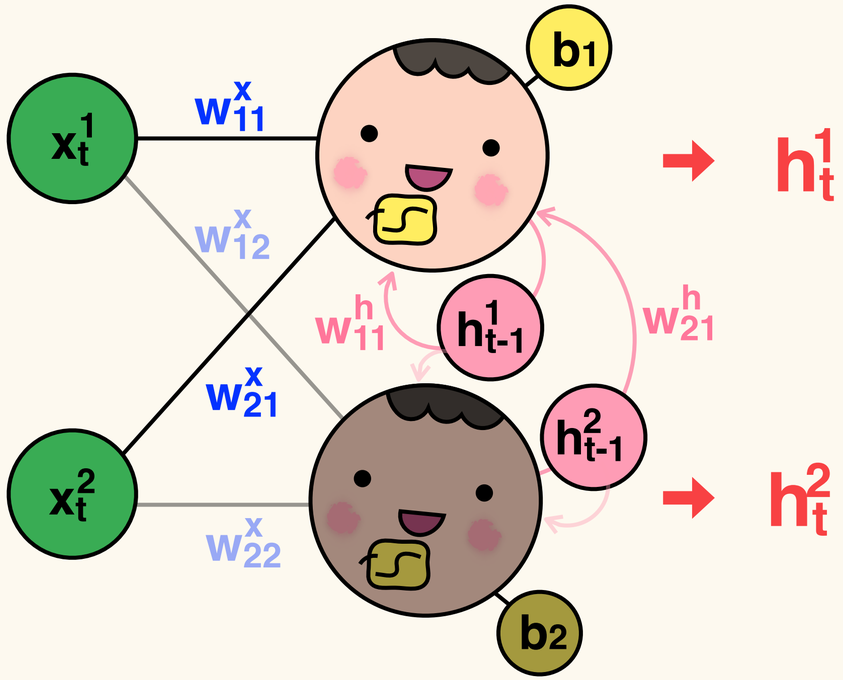

然後才決定這次的輸出。

$$h_t^1 = \sigma(w_{11}^x x_t^1 + w_{21}^x x_t^2 + w_{11}^h h_{t-1}^1 + w_{21}^h h_{t-1}^2 + b_1)$$

認真看 RNN 神經元就是一般的神經元

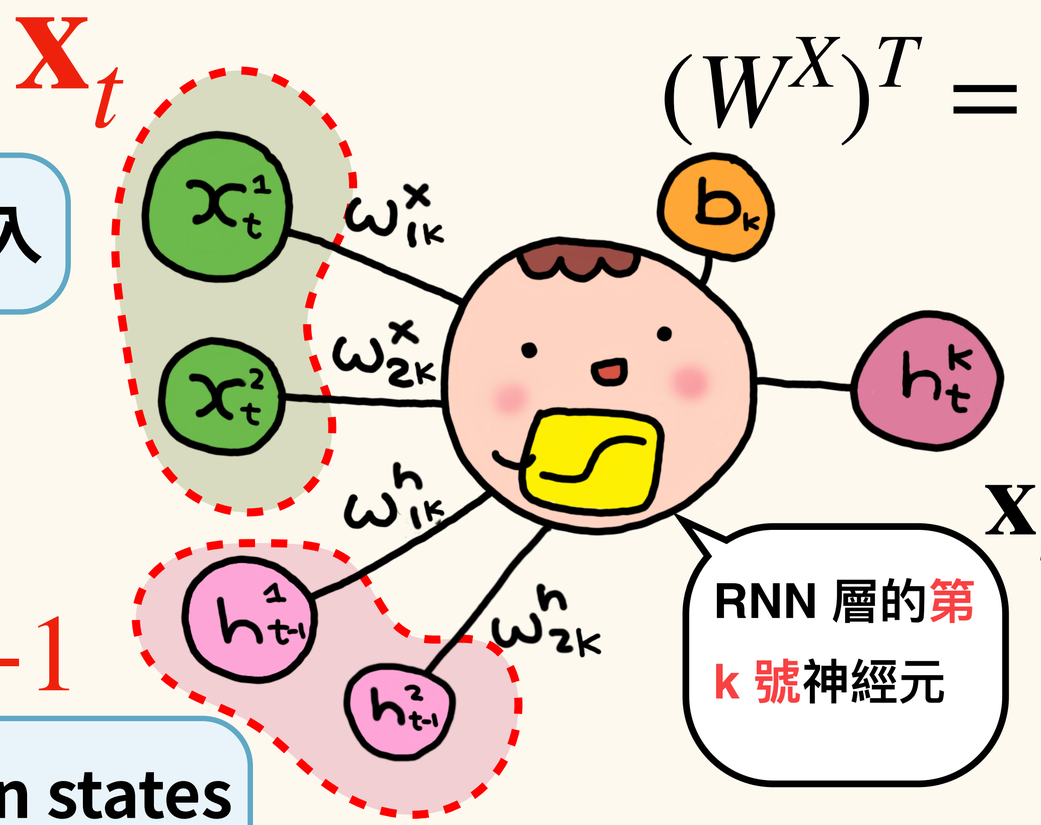

「正常」輸入

上次的 hidden states

RNN 層的第 k 號神經元

$$(W^X)^T = \begin{bmatrix} w_{11}^x & w_{21}^x \\ w_{12}^x & w_{22}^x \end{bmatrix}$$

$$\mathbf{x}_t = \begin{bmatrix} x_t^1 \\ x_t^2 \end{bmatrix}$$

認真看 RNN 神經元就是一般的神經元

$$(W^X)^T \cdot \mathbf{x}_t = \begin{bmatrix} w_{11}^x x_t^1 + w_{21}^x x_t^2 \\ w_{12}^x x_t^1 + w_{22}^x x_t^2 \end{bmatrix}$$

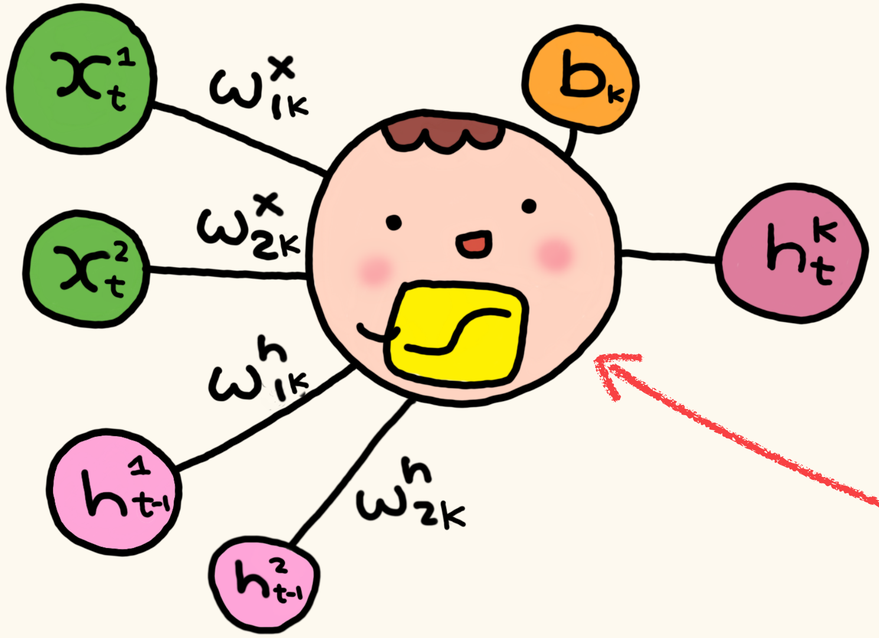

同時算了兩個神經元的!

1 號 RNN 神經元 ($k = 1$)

Hiden States 這邊基本上也是一樣的!

$$(W^H)^T \cdot \mathbf{h}_{t-1} = \begin{bmatrix} w_{11}^h h_{t-1}^1 + w_{21}^h h_{t-1}^2 \\ w_{12}^h h_{t-1}^1 + w_{22}^h h_{t-1}^2 \end{bmatrix}$$

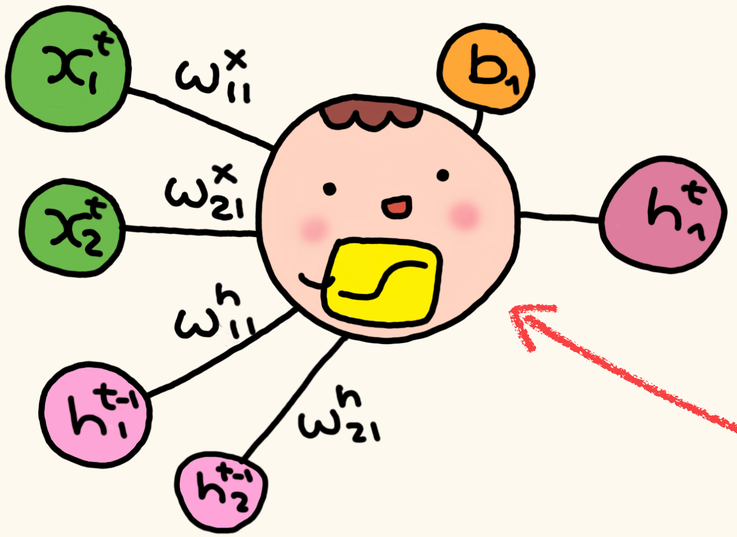

同時算了兩個神經元的!

1 號 RNN 神經元 ($k = 1$)

02.

線性代數 101

矩陣最大的關鍵就是先列後行!

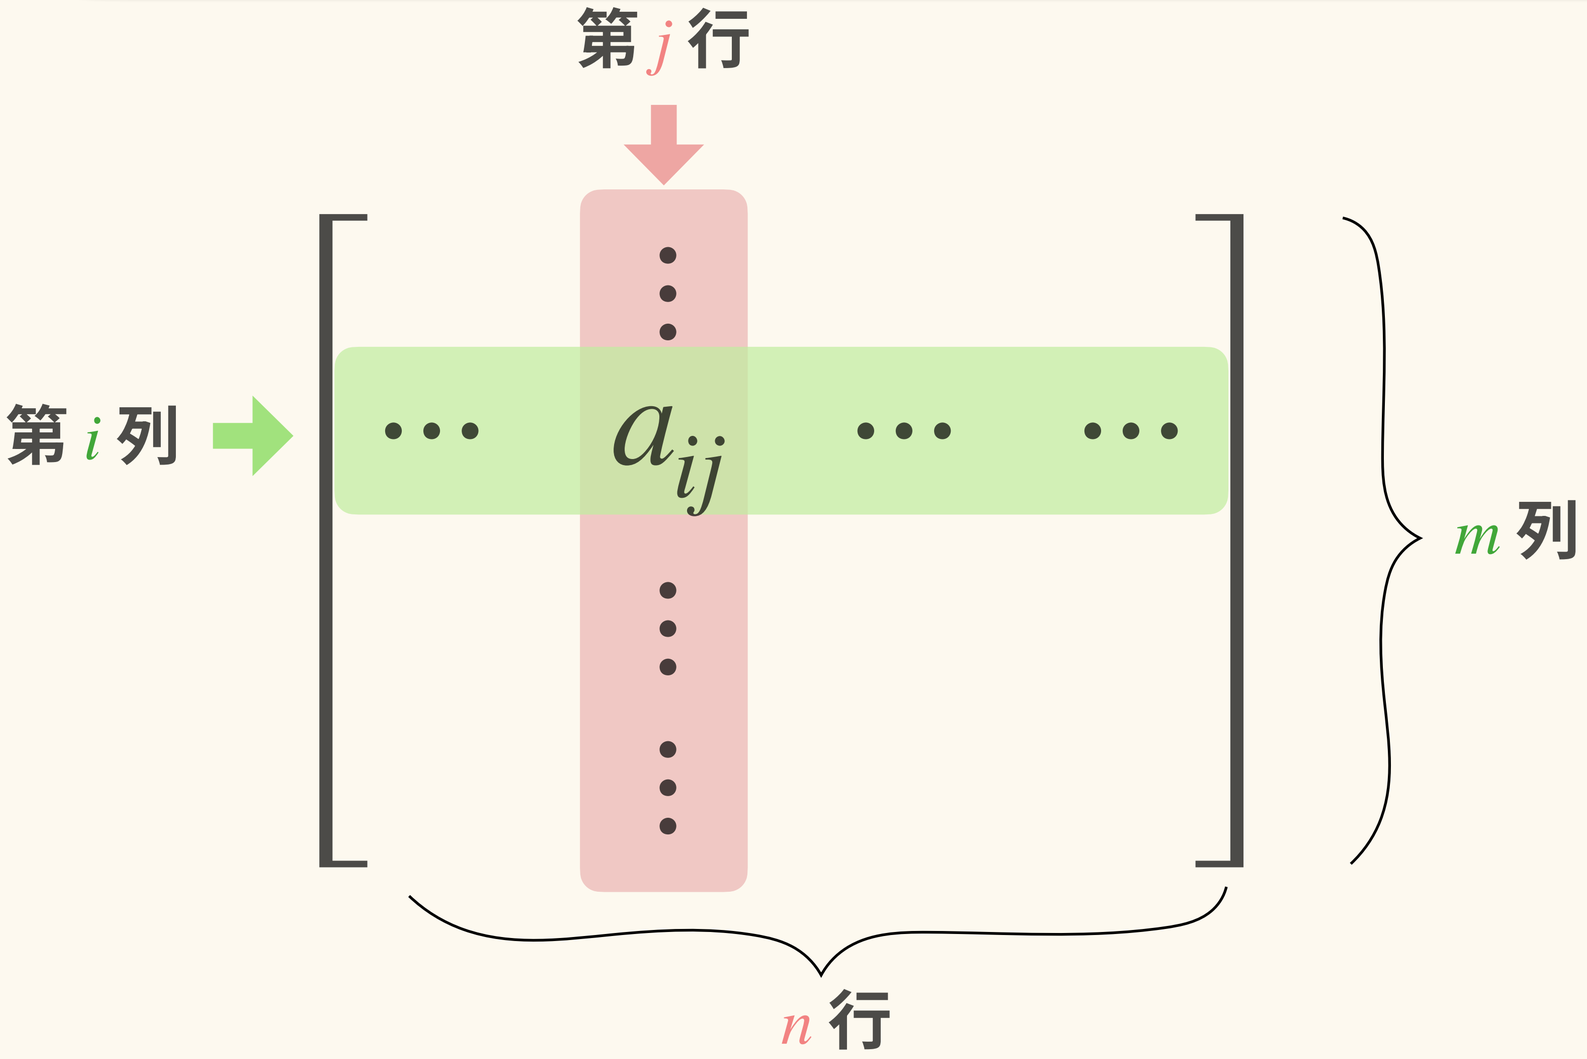

a_{ij}

列 行

$m \times n$ 矩陣

列 行

乘法也是先列後行

第 j 行

第 i 列

$$\begin{bmatrix} \vdots \\ \cdots\ a_{ik}\ \cdots\ \cdots \\ \vdots \end{bmatrix} \cdot \begin{bmatrix} \cdots\ \vdots\ \cdots\ \cdots \\ \cdots\ b_{kj}\ \cdots\ \cdots \\ \cdots\ \vdots\ \cdots\ \cdots \end{bmatrix}$$

若 $C = AB$, c_{ij} 是 A 矩陣第 i 列和 B 矩陣第 j 行的內積。

內積（嚴格說是 dot product）是核心

設 $\mathbf{u} = [a_1, a_2, \ldots, a_p]$, $\mathbf{v} = [b_1, b_2, \ldots, b_p]$

$$\langle \mathbf{u}, \mathbf{v} \rangle = \mathbf{u}\mathbf{v}^T = \begin{bmatrix} a_1, a_2, \ldots, a_p \end{bmatrix} \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_p \end{bmatrix}$$

列向量為中心的故事開展

一般我們說的線性轉換, 會寫成Ax。

但 Google 超喜歡列向量 (和內積), 於是引發了後面的故事...

矩陣乘法最重要技巧（線性轉換）

$$\mathbf{x} \quad \begin{bmatrix} x_1 & x_2 & \cdots & x_m \end{bmatrix} \quad \begin{bmatrix} \mathbf{a}_1 \\ \mathbf{a}_2 \\ \vdots \\ \mathbf{a}_m \end{bmatrix} \; A$$

正好由 x 向量的分量，
對 A 矩陣的列向量做
線性組合！

$$= x_1 \cdot \mathbf{a}_1 + x_2 \cdot \mathbf{a}_2 + \cdots + x_m \cdot \mathbf{a}_m$$

03.

QKV 注意力機制

Transformers 的誕生

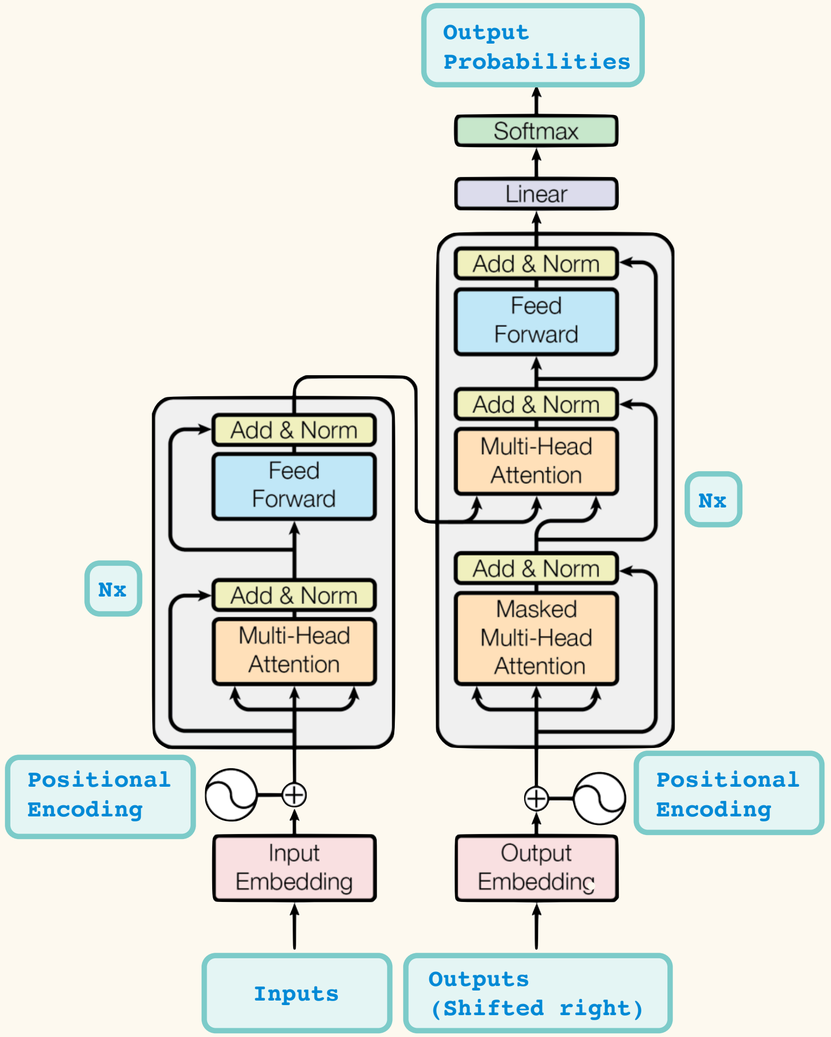

2017 年, Google 出了一篇有名的「Attention is All you need」, 介紹 transformers 的架構。最主要是想取代 RNN, 但從標題可知, (當時) Google 野心更大。

* "Attention is All you Need," Vaswani et. al., NIPS 2017

Attention 機制: 神秘的 QKV 概念

Q Query

K Key

V Value

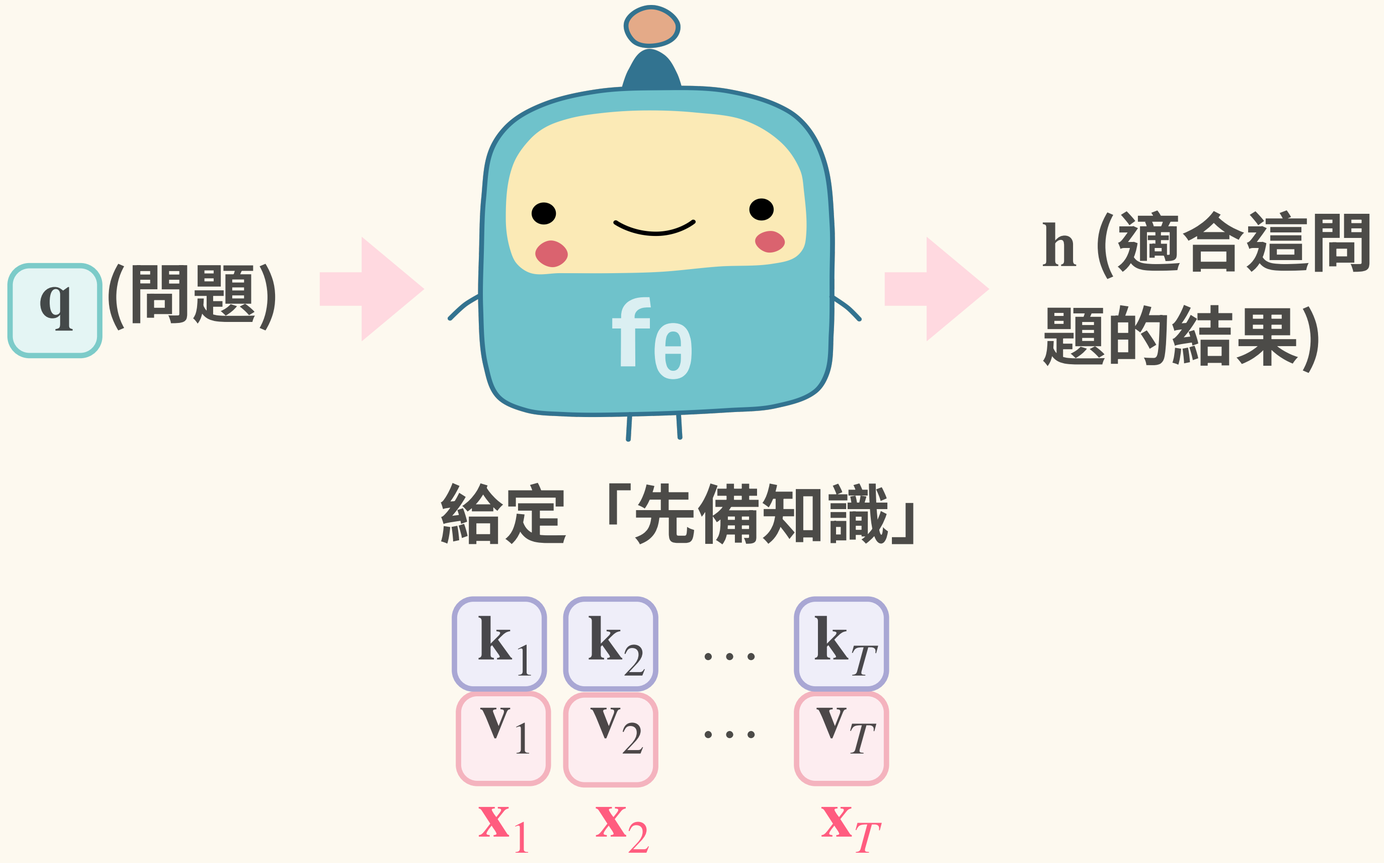

特徵代表向量

這裡的 $\mathbf{q}_t, \mathbf{k}_t, \mathbf{v}_t$ 都是 $\mathbf{x}_t$ 的一個特徵代表向量。

$$\mathbf{x}_t \rightarrow \mathbf{q}_t \quad \mathbf{k}_t \quad \mathbf{v}_t$$

希望找到 Q 適合的代表向量

直覺的想法是有一段資訊, 比方說一段文字 $\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_T$, 現在有個 query $\mathbf{q}$ 進來, 想依前面的資訊, 找出最適合 $\mathbf{q}$ 的代表向量 $\mathbf{h}$。

$\mathbf{q}$ → $\mathbf{h}$

最後這個向量長這樣

$$\mathbf{h} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \cdots + \alpha_T \mathbf{v}_T$$

$\mathbf{q}$ 和 $\mathbf{x}_1$ 的相關強度

$\mathbf{q}$ 和 $\mathbf{x}_T$ 的相關強度

$\mathbf{q}$ 和 $\mathbf{x}_2$ 的相關強度

所謂相關強度是 attention 的強度, 基本上愛怎麼合理的算都可以

計算「注意力」的強度

Attentation (alignment)

$$a(\mathbf{q}, \mathbf{k}_t) = \langle \mathbf{q}, \mathbf{k}_t \rangle$$

$$= \mathbf{q}\mathbf{k}_t^T = e_t$$

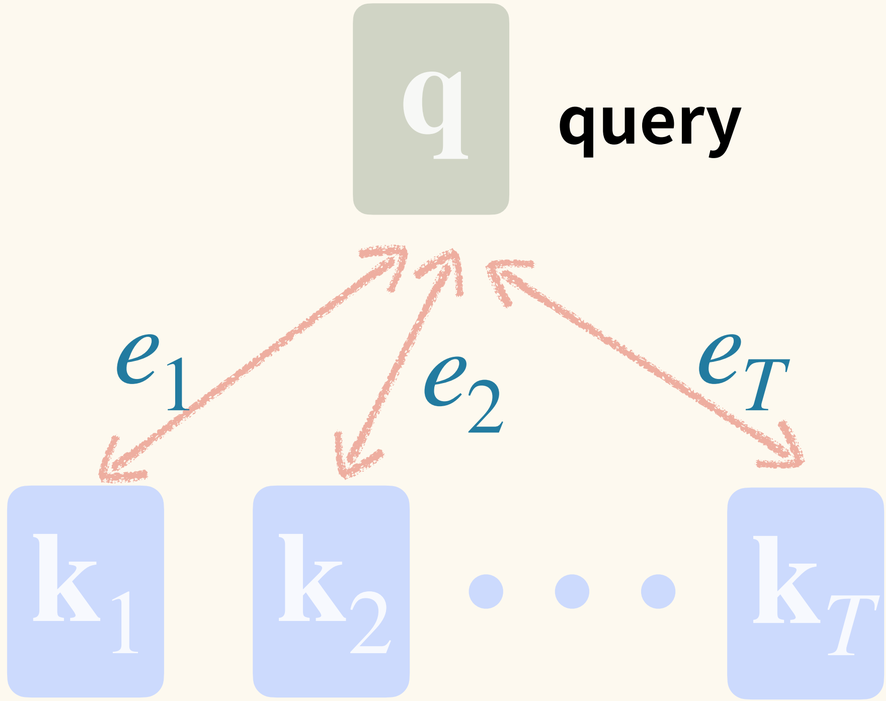

這是 Google 最愛的方法

把所有的 $\mathbf{k}_i$, $\mathbf{v}_i$ 放入一個矩陣

$$\mathbf{K} = \begin{bmatrix} \mathbf{k}_1 \\ \mathbf{k}_2 \\ \vdots \\ \mathbf{k}_T \end{bmatrix} \qquad \mathbf{V} = \begin{bmatrix} \mathbf{v}_1 \\ \mathbf{v}_2 \\ \vdots \\ \mathbf{v}_T \end{bmatrix}$$

深愛列向量的 Google, 顯然會這樣寫

Attentation 強度只是簡單矩陣乘法一次算完

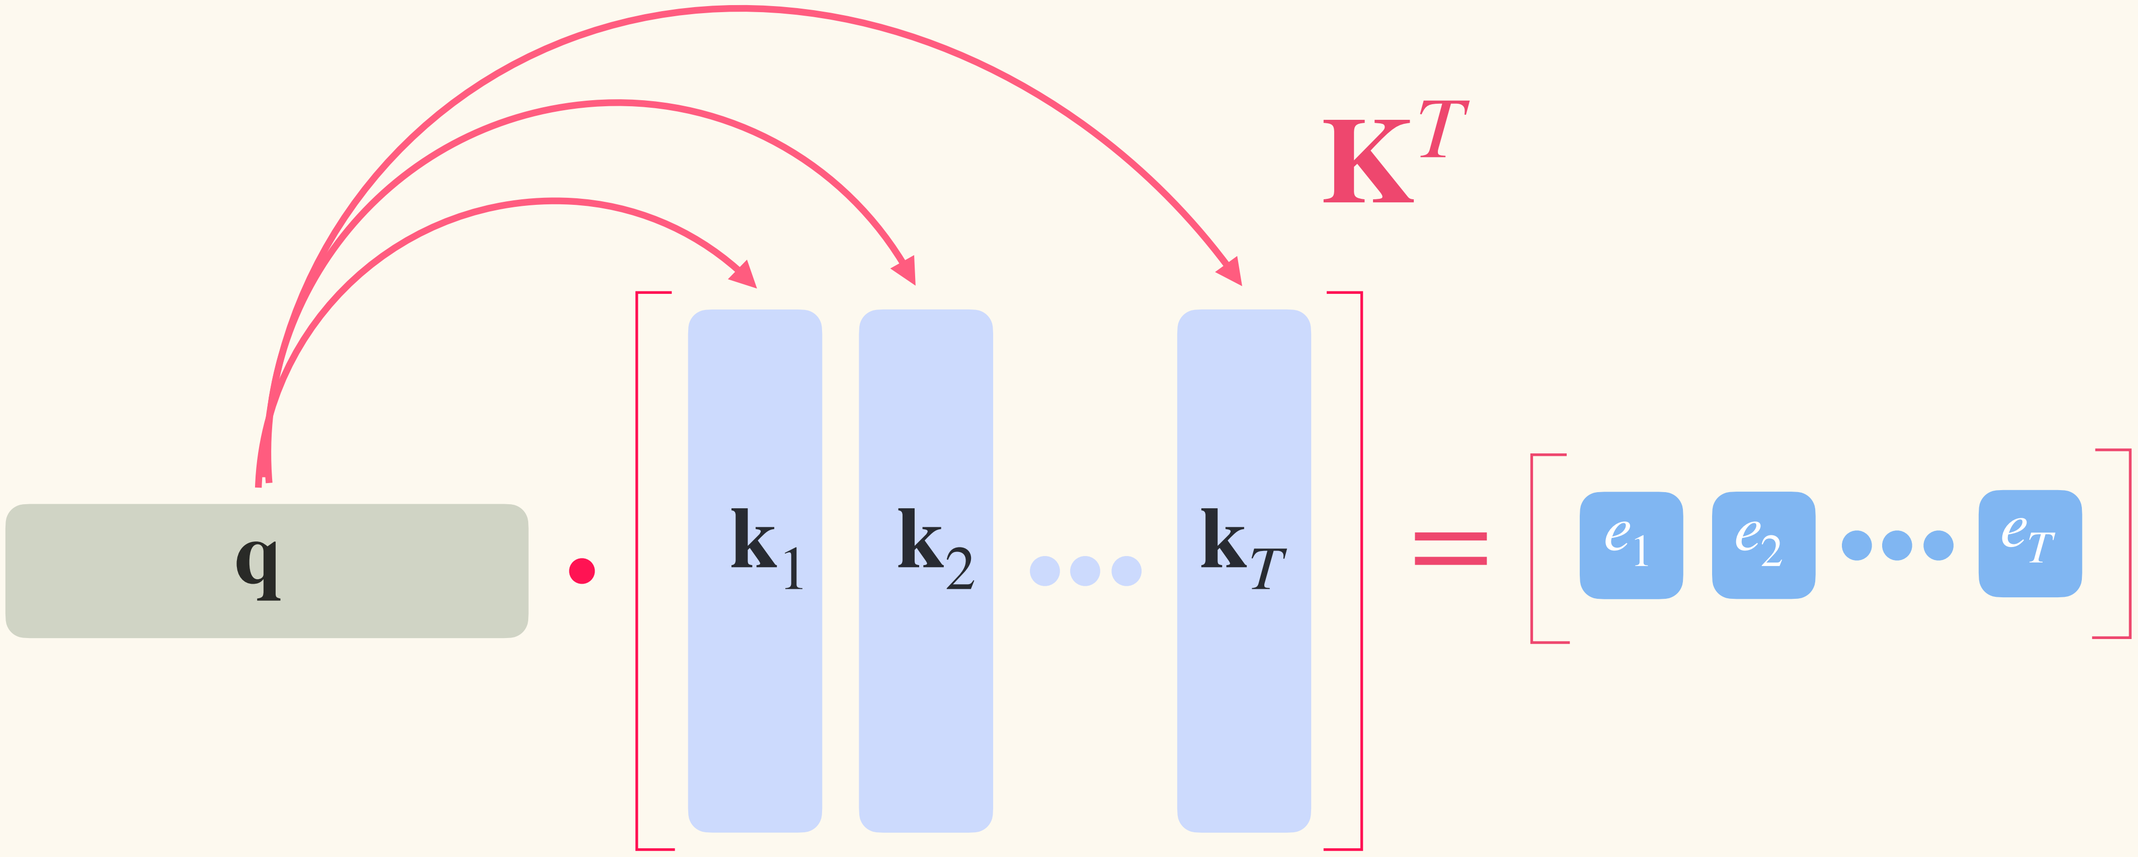

再經 softmax 就是最後權重係數

$$\mathbf{q} \cdot \begin{bmatrix} \mathbf{k}_1 & \mathbf{k}_2 & \cdots & \mathbf{k}_T \end{bmatrix} = \begin{bmatrix} e_1 & e_2 & \cdots & e_T \end{bmatrix}$$

$\mathbf{K}^T$

softmax

$$\begin{bmatrix} \alpha_1 & \alpha_2 & \cdots & \alpha_T \end{bmatrix}$$

$$\mathbf{h} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \cdots + \alpha_T \mathbf{v}_T$$

式子可以很美

$$\text{softmax}(\mathbf{q} \cdot K^T) = \begin{bmatrix} \alpha_1 & \alpha_2 & \cdots & \alpha_T \end{bmatrix}$$

$$\begin{bmatrix} \alpha_1 & \alpha_2 & \cdots & \alpha_T \end{bmatrix} \begin{bmatrix} \mathbf{v}_1 \\ \mathbf{v}_2 \\ \vdots \\ \mathbf{v}_T \end{bmatrix}_V = \sum_{t=1}^{T} \alpha_t \mathbf{v}_t$$

記得這乘法就是
列向量線性組合

最終美美的 (?) 式子長這樣

$$\text{Attention}(\mathbf{q}, K, V) = \text{softmax}(\mathbf{q} \cdot K^T)V$$

Self-Attention

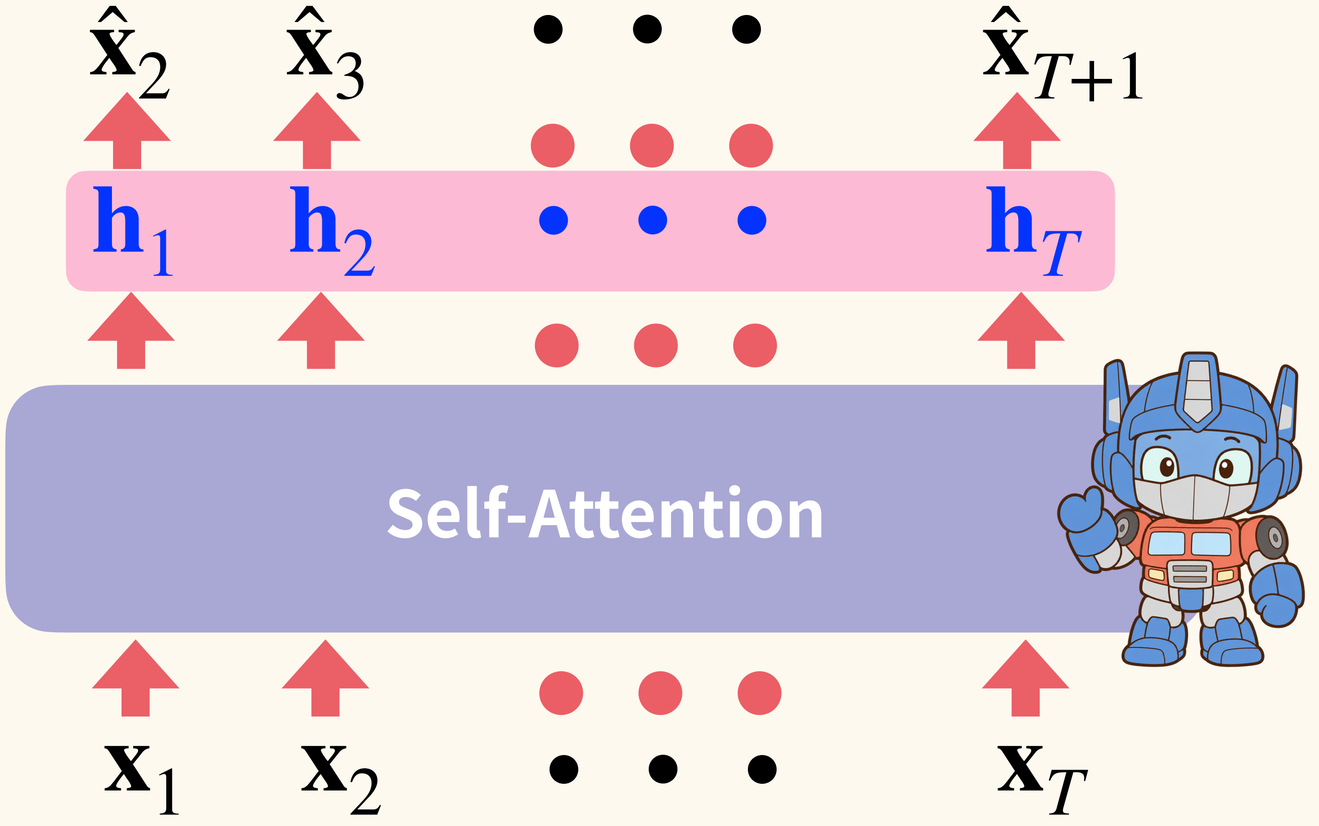

基本上是每個 x 再增加 q 特徵代表向量

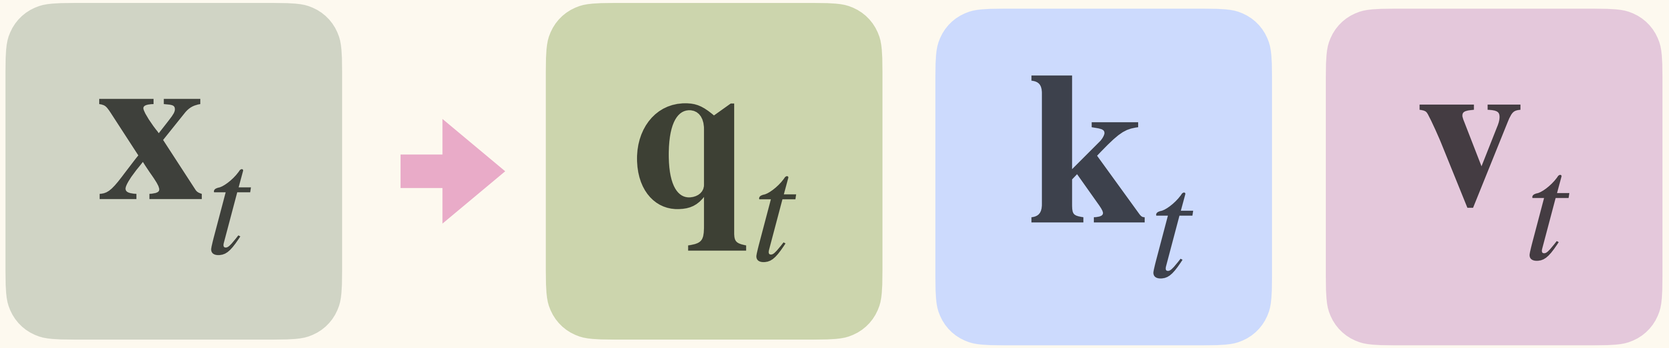

其實就是大家輪流當 q

就是標準
attention 計算

$$\mathbf{q}_j \rightarrow \mathbf{h}_j = \sum_{t=1}^{T} \alpha_t \mathbf{v}_t$$

$$\mathbf{x}_1 \quad \mathbf{x}_2 \quad \cdots \quad \mathbf{x}_j \quad \cdots \quad \mathbf{x}_T$$

像 K, V 一樣, 把所有 $\mathbf{q}_i$ 放入一個矩陣

$$\mathbf{Q} = \begin{bmatrix} \mathbf{q}_1 \\ \mathbf{q}_2 \\ \vdots \\ \mathbf{q}_T \end{bmatrix}$$

就像前面說明的, 很容易可以導出 Google 引以為傲的公式。

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T)V$$

One More Thing

你可能會發現前面的公式和原始論文公式不同, 那是因為 Google 很尷尬的發現, 用內積算 attention 強度其實效果沒有人家 (比如訓練一個神經元去算) 好。主要原因是 softmax 是「贏者通吃」, 會讓權重高的比合理權重還要高很多。

好在這不難救...

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

$d_k = \dim(\mathbf{k}_i)$, 其實這裡放一個足夠大適當的數字就可以, 比如 $\sqrt{9487}$。Google 這樣寫基本上只是讓你覺得好有學問...

Softmax 贏者通吃

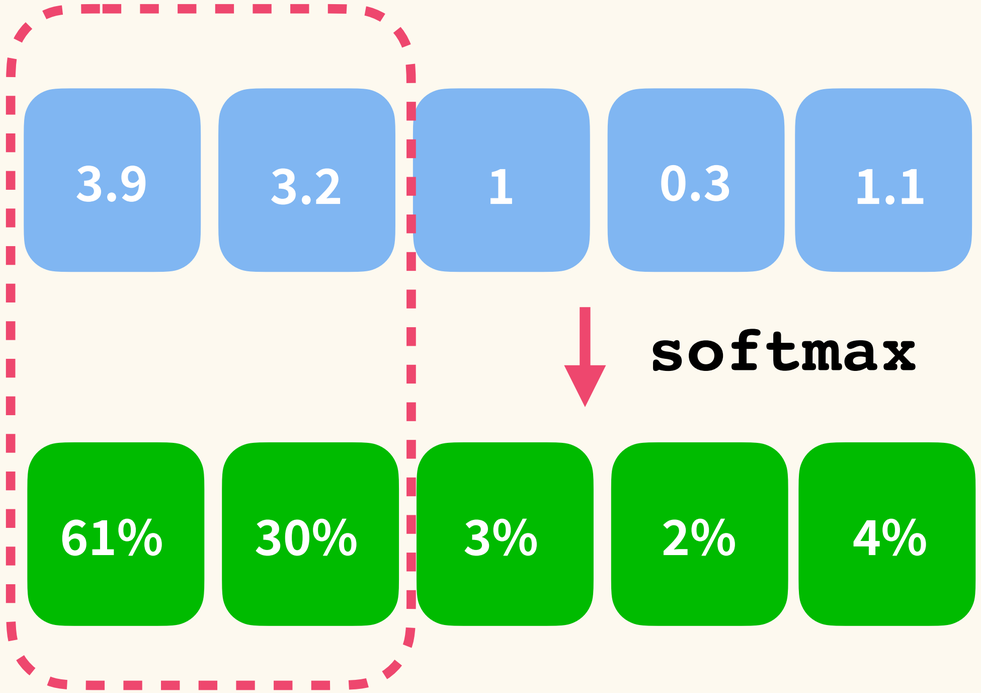

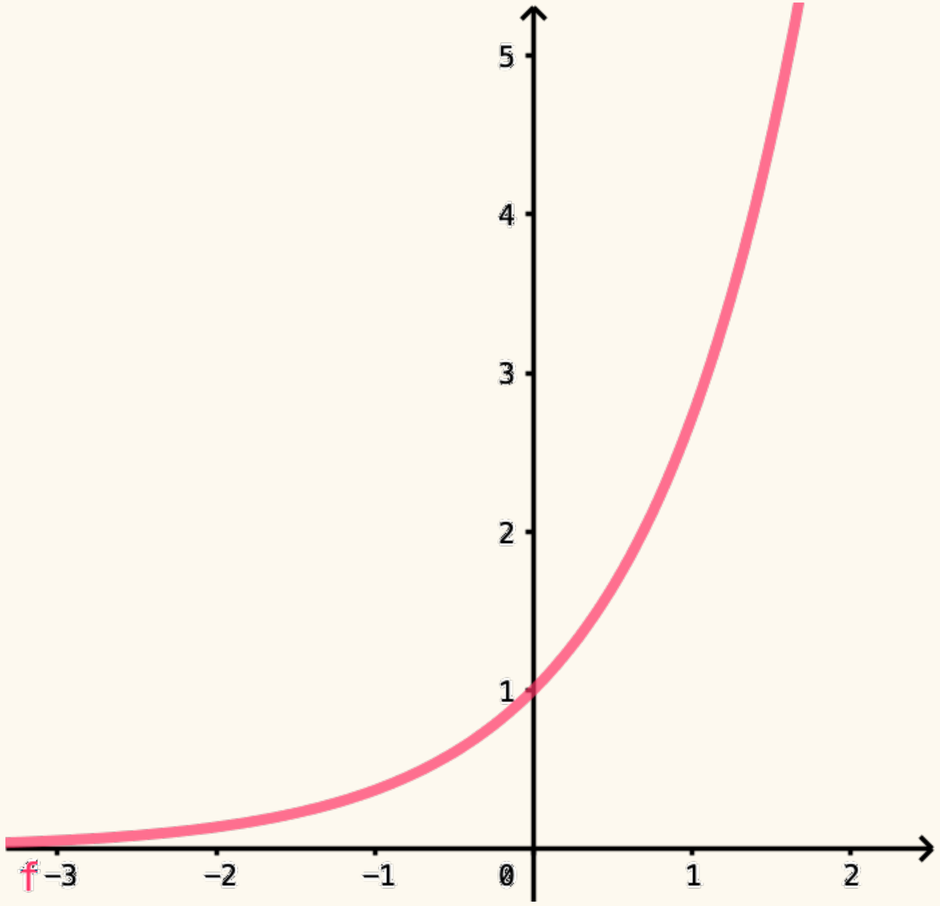

本來感覺只差一點啊...

把數字都拉到 0 的附近，輕鬆解決問題

3.9 3.2 1 0.3 1.1

同除以 $\tau = \sqrt{d_k}$

1.74 1.43 0.45 0.13 0.49

softmax

40% 29% 11% 8% 11%

τ 當然不一定要是 $\sqrt{d_k}$，可以當一個 hyperparameter!

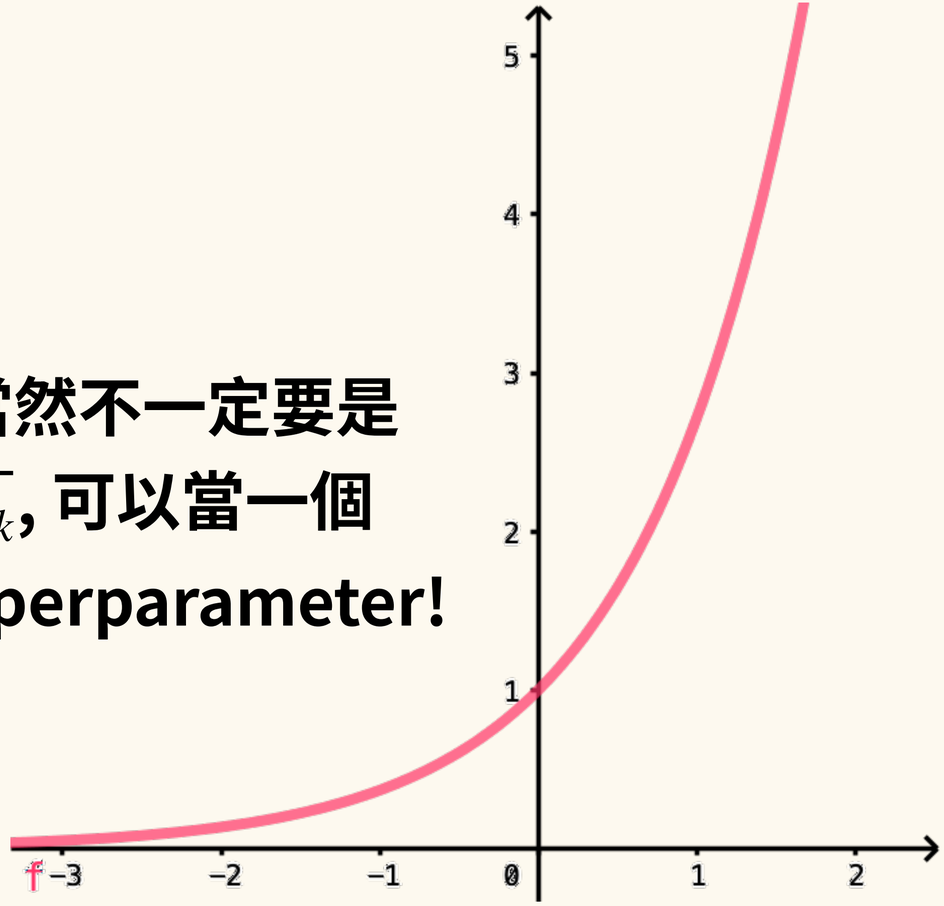

回過頭看各個向量是怎麼來的

$\mathbf{x}_1$ $\mathbf{x}_2$ $\cdots$ $\mathbf{x}_T$ 是 word embedding*

$$\mathbf{q}_t = \mathbf{x}_t W^Q, \mathbf{k}_t = \mathbf{x}_t W^K, \mathbf{v}_t = \mathbf{x}_t W^V$$

就是經過對 $\mathbf{x}_i$ 的線性轉換, 這些矩陣是學習來的

* 一般不用如 Word2Vec 等標準 word embedding, 而是直接加 embedding 層去學

注意 Q、K、V 都可以一次算出來

$$X = \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \\ \vdots \\ \mathbf{x}_T \end{bmatrix}$$

注意 Q, K, V 就是：

$$Q = \mathbf{X}W^Q$$
$$K = \mathbf{X}W^K$$
$$V = \mathbf{X}W^V$$

Multihead Attention

認真想想, attention 沒理由只有一種, 所以我們可以定義第 n 個 attention...

$$\text{Attention}(\underbrace{XW_n^Q}_{Q}, \underbrace{XW_n^K}_{K}, \underbrace{XW_n^V}_{V})$$

encoder 和 decoder 設計是不同的

這兩處的 self-attenation 都是由輸入向量自家生產 $\mathbf{q}, \mathbf{k}, \mathbf{v}$

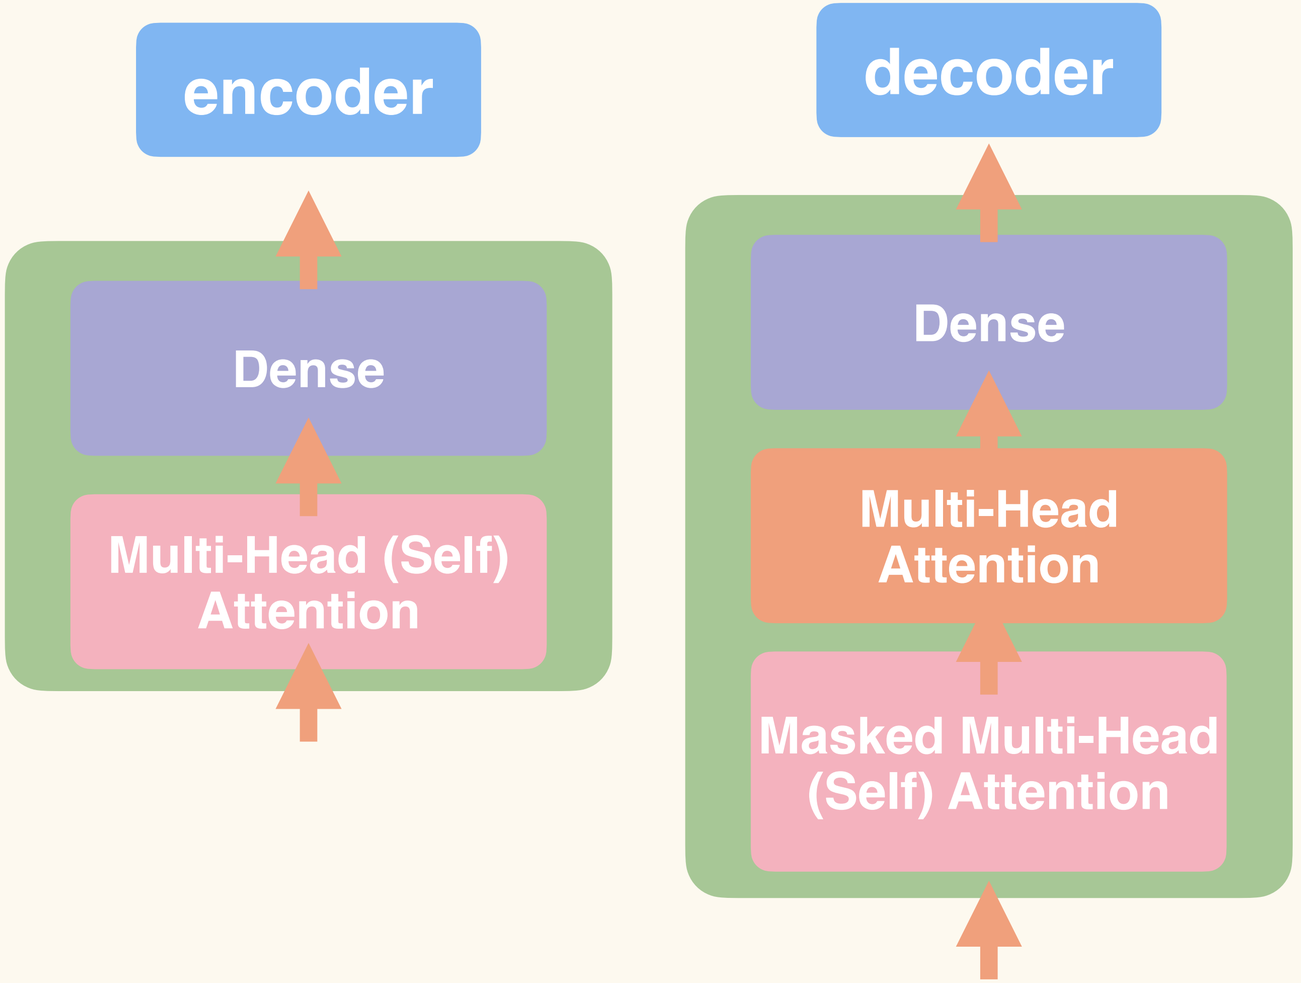

只有 decoder 中間那層不是 self-attention

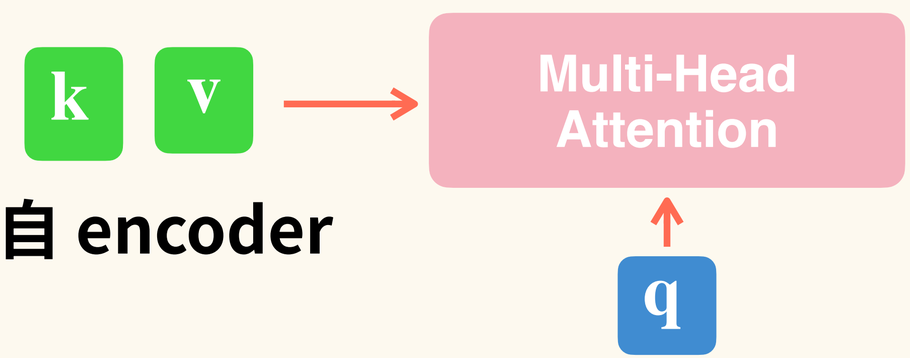

來自 encoder

來自前一層的 output

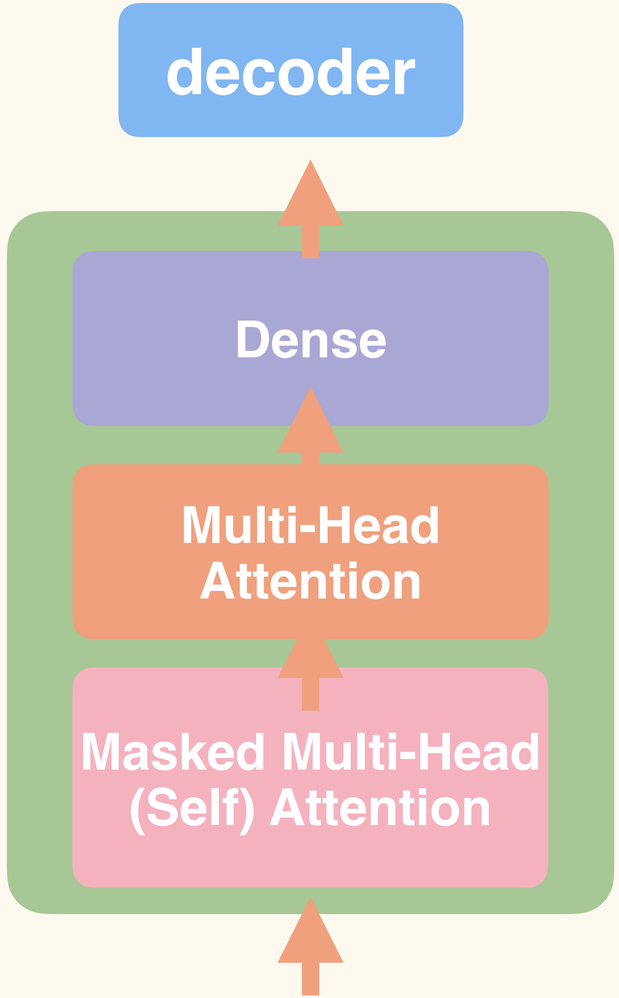

Masked Multihead Attention

要注意的是, transformer 輸入有幾個 (字/詞向量), 輸出就有幾個。

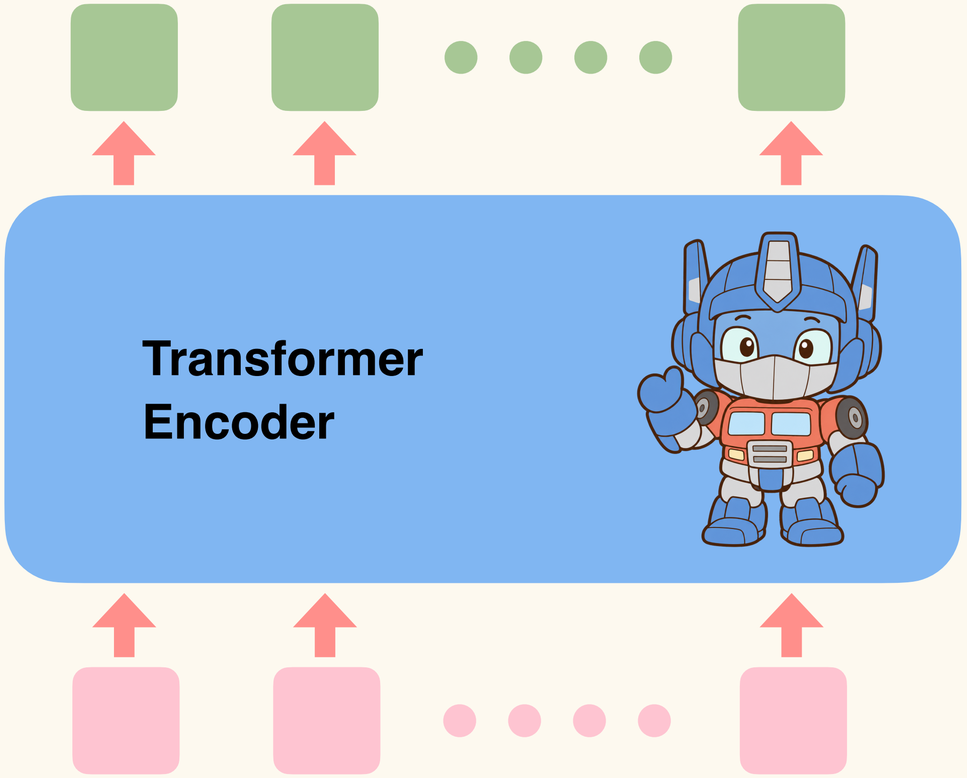

Masked Multihead Attention

包括 Decoder 也是這樣, 只是開始還沒有的輸入會被 mask 住。

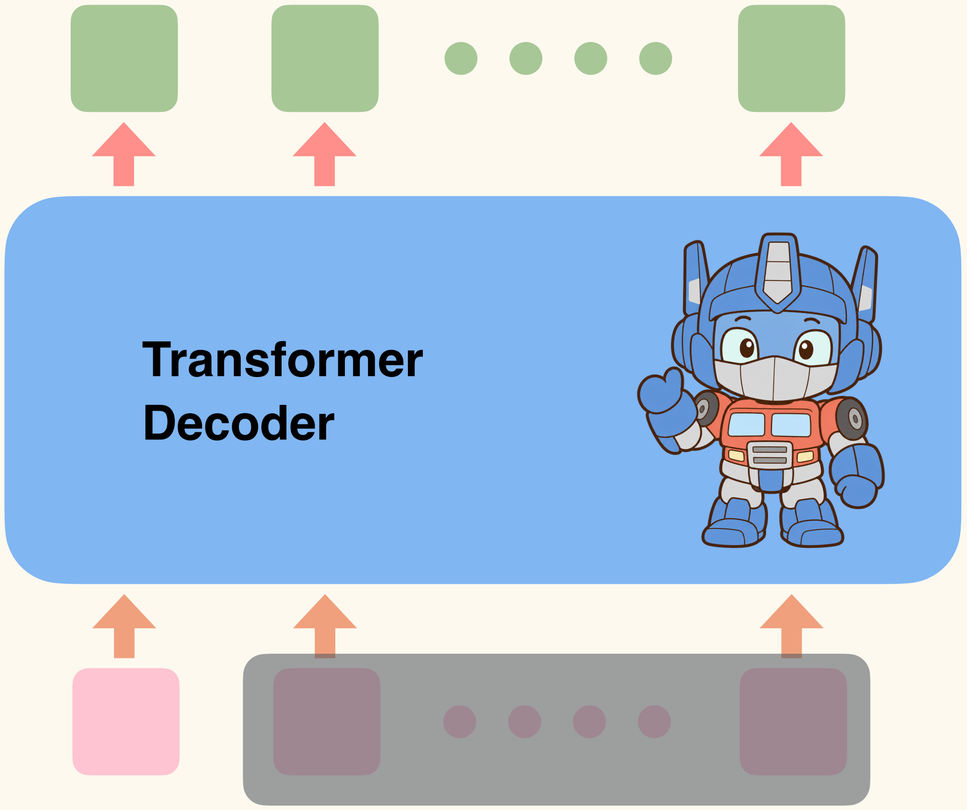

04.

Position Encoding

Position Encoding

注意 RNN 是真的一個字一個字讀, transformers 為了平行化, 一次做 self-attention, 每個字先後順序並沒有真的被考慮。所以我們應該要把位置資訊加入原來文字 embedding, 這叫 position encoding。

$$\mathbf{x}_t + \mathbf{p}_t$$

word embedding　　position encoding

觀察任何一個進位的數字系統

越高位數週期越長, 頻率越低。

比如我們熟悉的十進位數:

頻率 1/1000　頻率 1/10　頻率 1

[9, 4, 8, 7]

頻率 1/100

注意文字表示是相反的，比較像 [7, 8, 4, 9]

為了通用, 我們想找個奇幻進位系統

- ☑ 連續函數
- ☑ 有週期性
- ☑ 數值不要太大 (以免影響原 embedding)

加上 position encoding

注意這是低位數!

這是高位數!

$$\mathbf{p}_t = \left[p_1, p_2, \ldots, p_d \right]$$

$$+$$

$$\mathbf{x}_t = \left[x_1, x_2, \ldots, x_d \right]$$

原論文兩兩一組同頻率

$$\left[\underbrace{p_0, p_1}_{\omega_0}, \ldots, \underbrace{p_{2k}, p_{2k+1}}_{\omega_k}, \ldots, p_{d-1}\right]$$

* 注意原論文足標通常是從 1 開始，但這裡應該要由 0 開始才符合後面的式子。

$$\omega_k = \frac{1}{10000^{2k/d}}$$

記得低位數在前面, 後面的頻率要越來越慢, 需要 $\omega_0 > \omega_1 > \cdots$

原論文的 position encoding 方式

$$\mathbf{p}_t = \left[p_0, p_1, \ldots, p_{d-1} \right]$$

$$p_i = \begin{cases} \sin(\omega_k \cdot t), & \text{當 } i = 2k \\ \cos(\omega_k \cdot t), & \text{當 } i = 2k+1 \end{cases}$$

第 t 個字

位數越高頻率越低

Position Encoding

$$\mathbf{p}_t = [\sin(w_0)t, \cos(w_0)t,$$
$$\sin(w_1)t, \cos(w_1)t,$$
$$\vdots$$
$$\sin(w_{d/2})t, \cos(w_{d/2})t]$$

為什麼要加入 cos, 只有 sin 不行嗎?

沒人規定一個位元只能用一個數字表示, $(\sin(\omega_t t), \cos(\omega_t t))$
剛好是單位圓上的一點, 我們可以想成時鐘上的一個點。
只是位元低的時鐘快, 位元高的時鐘慢。

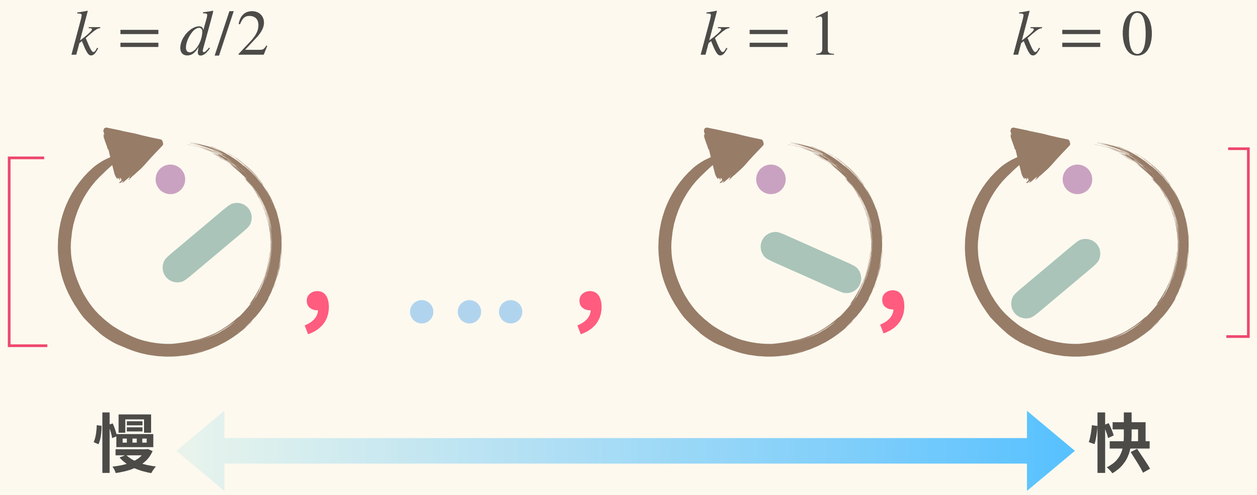

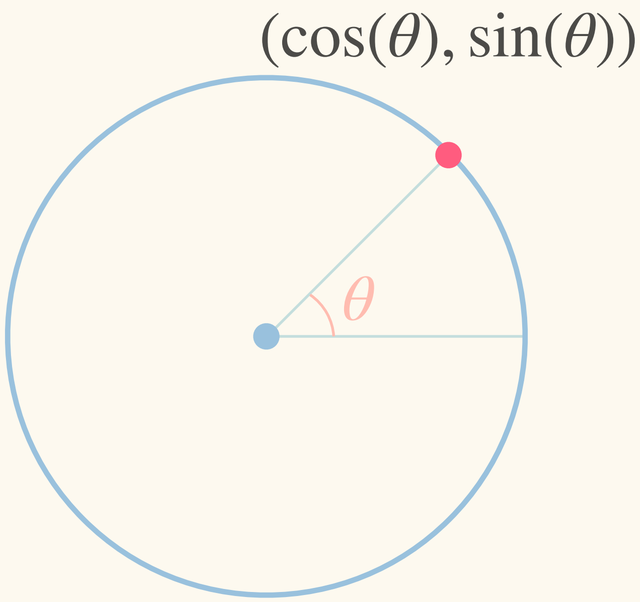

不要騙我不懂, 極座標明明是 cos 在前!

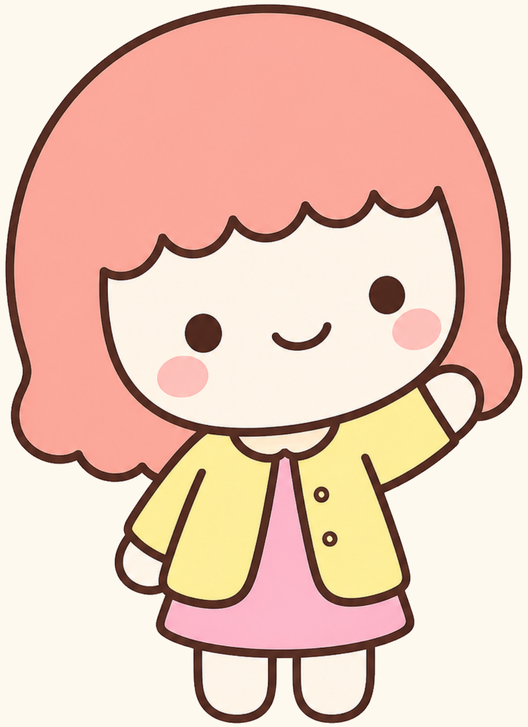

雖然不知 Google 的考量, 但 $(\sin(\theta), \cos(\theta))$ 繞一圈也是單位圓。而且 $\theta = 0$ 是指向一般時鐘 12 點方向, 並且走向會是順時鐘方向。

05.

讓 transformers 更穩

原版的 Transformers 架構

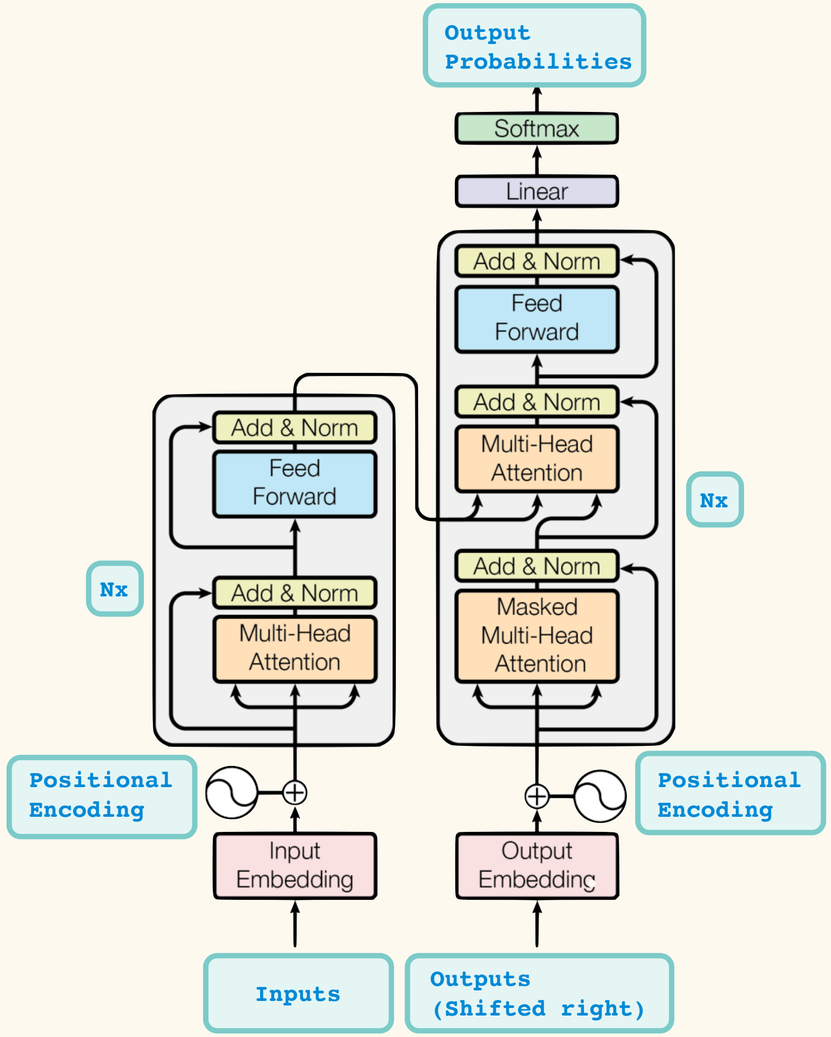

回頭看原本的 transformers 架構, 相信可以理解每一個細節了。我們沒有說的是 transformers 用了 residual 連結還有 layer normalization 的技術, 這些都是當年能讓神經網路更深、更穩定的最佳技術 (好在現在也差不多)。

Transformers 中有個 ResNet 型的設計

ResNet 的設計方式

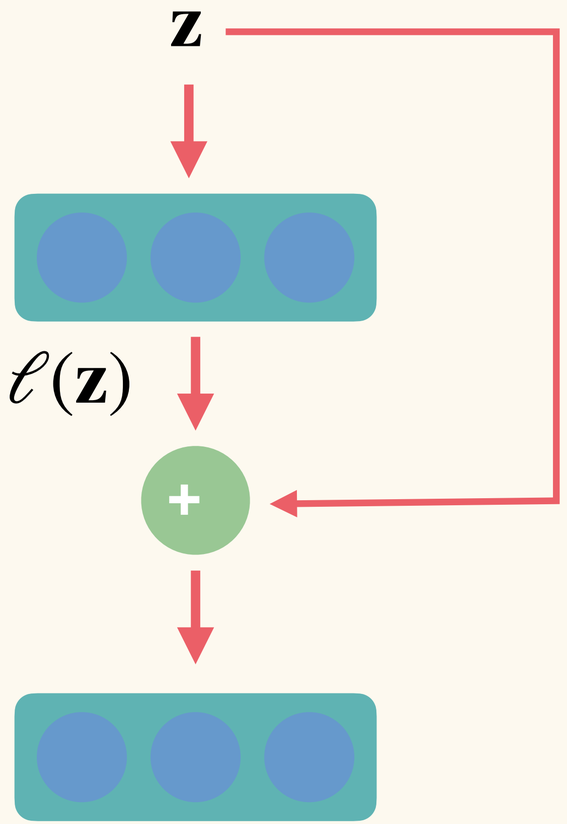

為什麼 ResNet 可以很深

這意思是本來某一層的輸出是

$$\ell(\mathbf{z})$$

現在變成

$$\mathbf{z} + \ell(\mathbf{z})$$

假設我們的目標 (**正確答案**) 是

$$f(\mathbf{z})$$

只需要學之前沒有學到的

也就是我們本來希望

$$\ell(\mathbf{z}) \simeq f(\mathbf{z})$$

現在變成

$$\mathbf{z} + \ell(\mathbf{z}) \simeq f(\mathbf{z})$$

之前學到的

還沒學到的

會把重心放在前方

目標

$$\ell(\mathbf{z}) = f(\mathbf{z}) - \mathbf{z}$$

已經學到的

如果 $\mathbf{z}$ 已經很接近正確答案 $f(\mathbf{z})$, 那 $\ell(\mathbf{z})$ 就不太需要再學什麼...

平順的 loss function

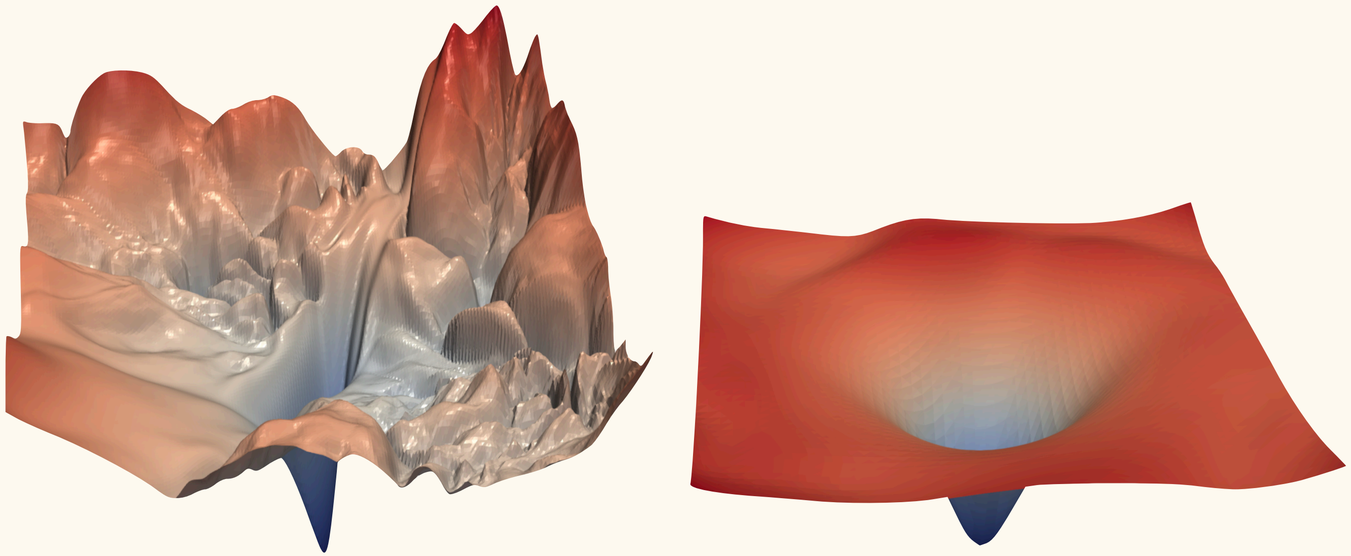

without skip **with skip**

Li,H., Xu, Z., Taylor, G., Studer C., Goldstein T. (NeuraIPS 2018).
Visualizing the Loss Landscape of Neural Nets. .

Batch Normalization

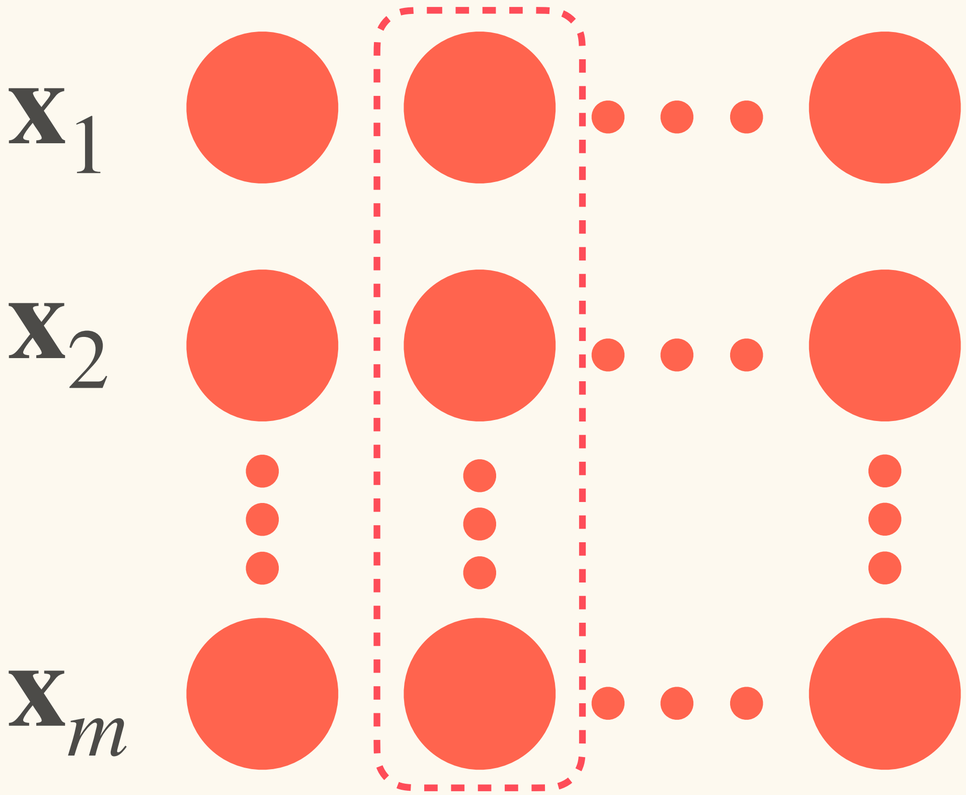

計算平均值、標準差

$$\hat{\mathbf{x}} = \frac{\mathbf{x} - \mu}{\sqrt{\sigma^2 + \varepsilon}}$$

預防除以 0

$$\mathbf{y} = \gamma\hat{\mathbf{x}} + \beta$$

學習來的

Layer Normalization (原版 transformers 的選擇)

$\mathbf{x}_i$

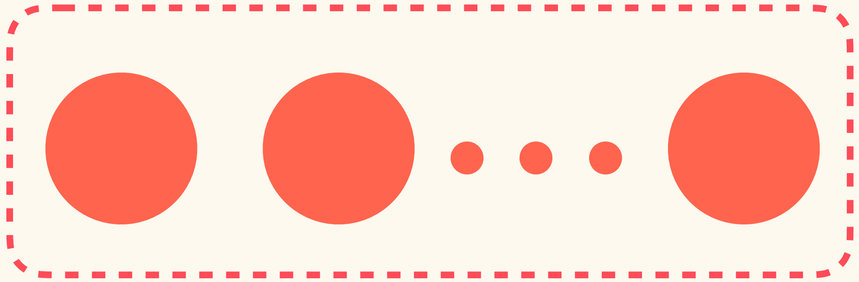

計算平均值、標準差

$$\hat{\mathbf{x}}_i = \frac{\mathbf{x}_i - \mu}{\sqrt{\sigma^2 + \varepsilon}}$$

預防除以 0

$$\mathbf{y}_i = \gamma \hat{\mathbf{x}}_i + \beta$$

學習來的

複習一下這些計算

$\mathbf{x}$ x_1 x_2 $\cdots$ x_n

1 **計算平均值**

$$\mu = \frac{1}{n}\sum_{i=1}^{n} x_i$$

2 **計算標準差**

$$\sigma = \sqrt{\frac{1}{n}\sum_{i=1}^{n} (x_i - \mu)^2}$$

仔細看 Layer Normalization

$\mathbf{x}$ x_1 x_2 $\cdots$ x_n

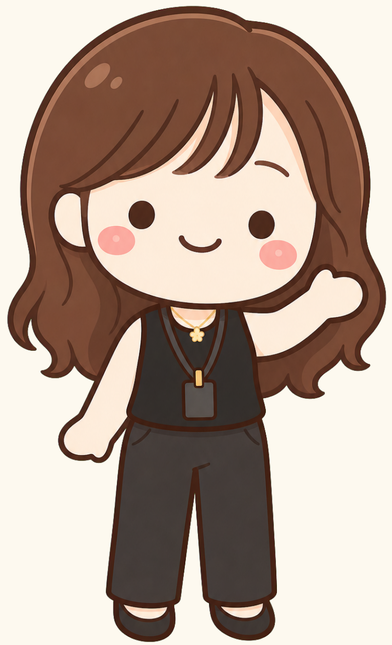

基本上都是如 numpy 的 broadcasting 運算。

這是向量

這是純量

$$\hat{\mathbf{x}} = \frac{\mathbf{x} - \mu}{\sqrt{\sigma^2 + \varepsilon}}$$

都是向量

$$\mathbf{y}_i = \gamma\hat{\mathbf{x}} + \beta$$

至此更新的模型也知道差異是什麼了

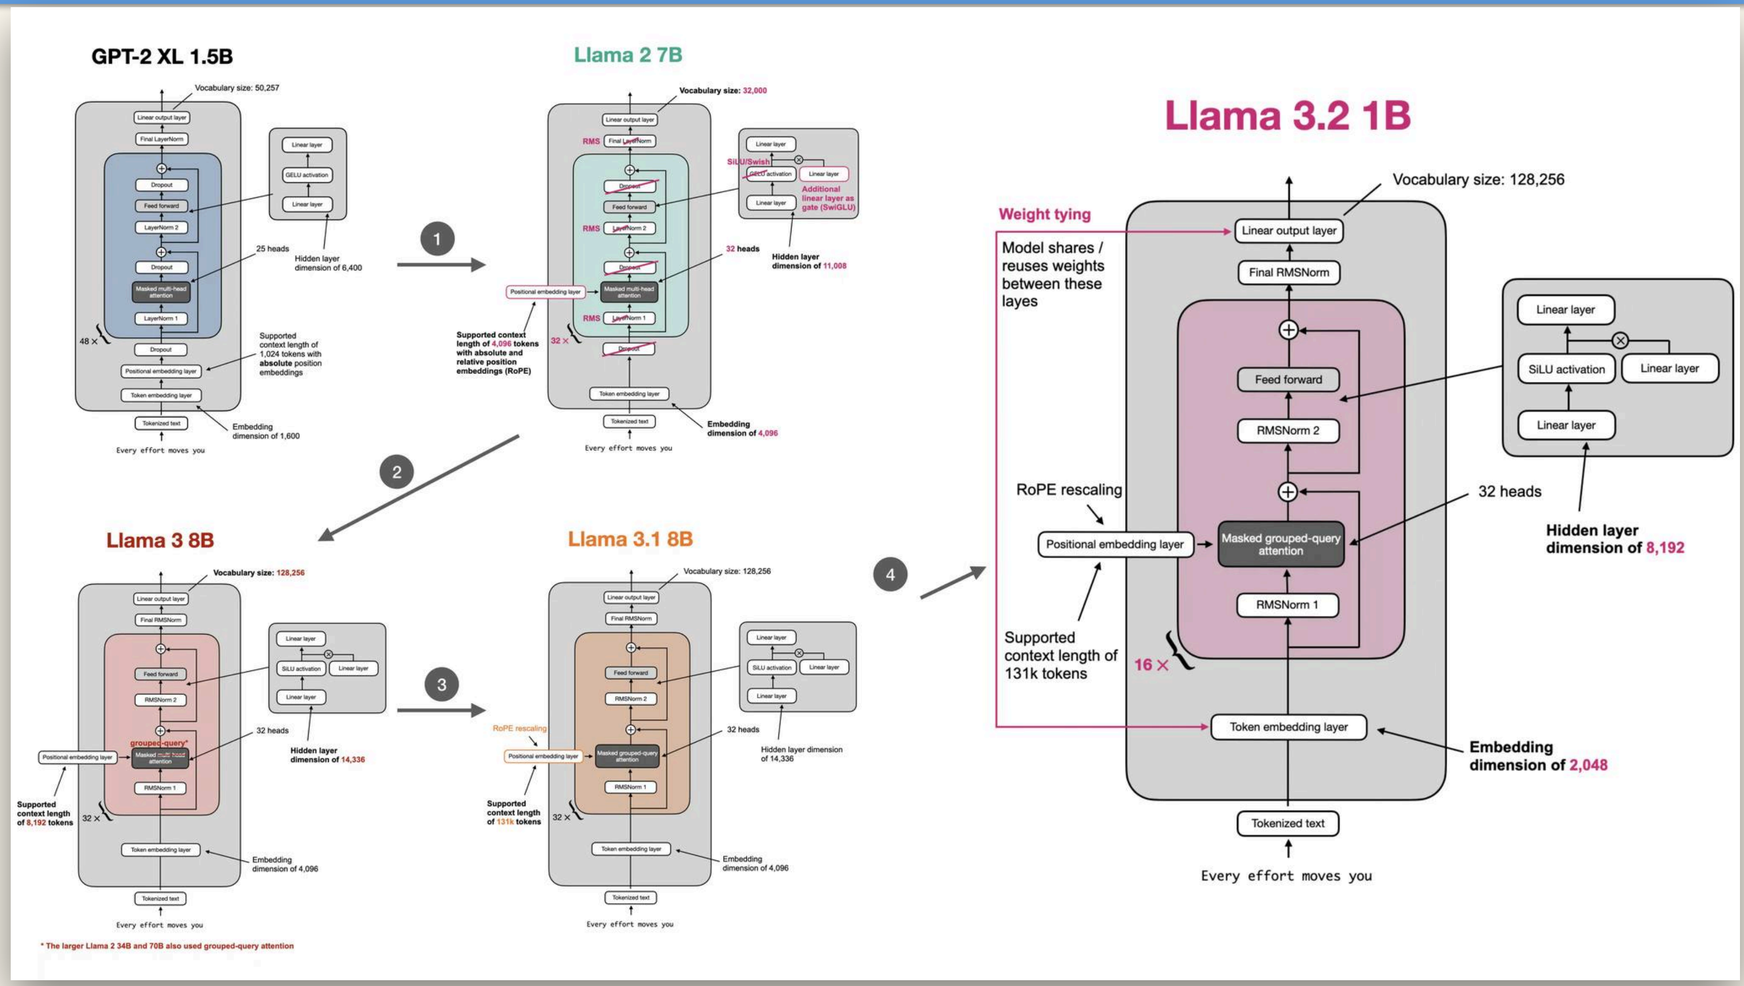

https://github.com/rasbt/LLMs-from-scratch

Llama 等 LLM 運用了 RMS Norm

$\mathbf{x}$ x_1 x_2 $\cdots$ x_n

$$\mathrm{RMS}(\mathbf{x}) = \sqrt{\frac{1}{n}\sum_{i=1}^{n} x^2}$$

$$\mathrm{RMSNorm}(\mathbf{x}) = \frac{\mathbf{x}}{\mathrm{RMS}(\mathbf{x})} \cdot \gamma$$

學來的向量

最近 Meta 說不用做 Normalization!

Transformers without Normalization

Jiachen Zhu[1,2], **Xinlei Chen**[1], **Kaiming He**[3], **Yann LeCun**[1,2], **Zhuang Liu**[1,4,†]

[1]FAIR, Meta, [2]New York University, [3]MIT, [4]Princeton University
[†]Project lead

Normalization layers are ubiquitous in modern neural networks and have long been considered essential. This work demonstrates that Transformers without normalization can achieve the same or better performance using a remarkably simple technique. We introduce Dynamic Tanh (DyT), an element-wise operation $\mathrm{DyT}(\boldsymbol{x}) = \tanh(\alpha \boldsymbol{x})$, as a drop-in replacement for normalization layers in Transformers. DyT is inspired by the observation that layer normalization in Transformers often produces tanh-like, S-shaped input-output mappings. By incorporating DyT, Transformers without normalization can match or exceed the performance of their normalized counterparts, mostly without hyperparameter tuning. We validate the effectiveness of Transformers with DyT across diverse settings, ranging from recognition to generation, supervised to self-supervised learning, and computer vision to language models. These findings challenge the conventional understanding that normalization layers are indispensable in modern neural networks, and offer new insights into their role in deep networks.

Date: March 14, 2025
Project page and code: jiachenzhu.github.io/DyT
Correspondence: jiachen.zhu@nyu.edu, zhuangl@princeton.edu

Meta

可設為 0.5

Dynamic Tanh

$$\mathrm{DyT}(\mathbf{x}) = \gamma \cdot \tanh(\alpha \mathbf{x}) + \beta$$

學習來的向量

不只是文字, 圖像 (聲音、時間序列數據) 也可以

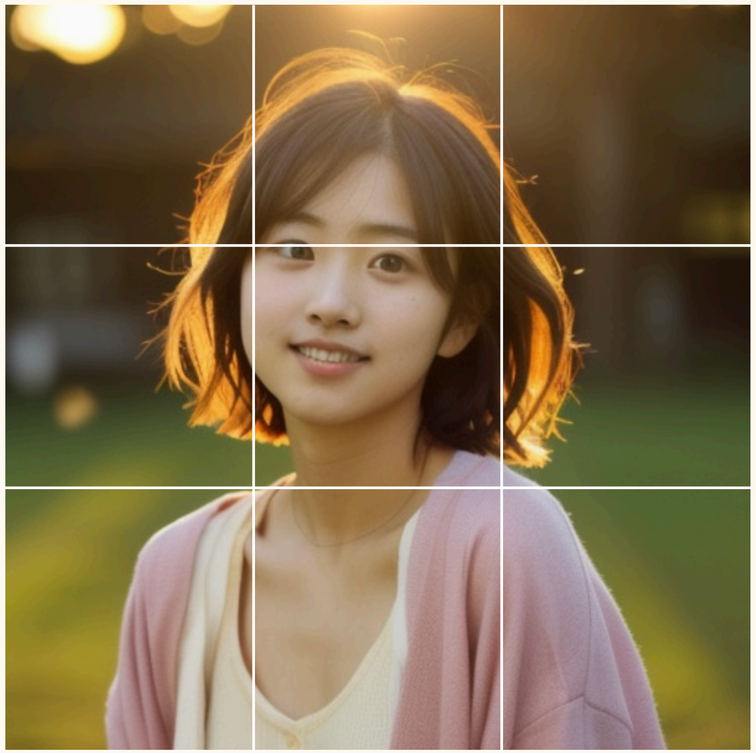

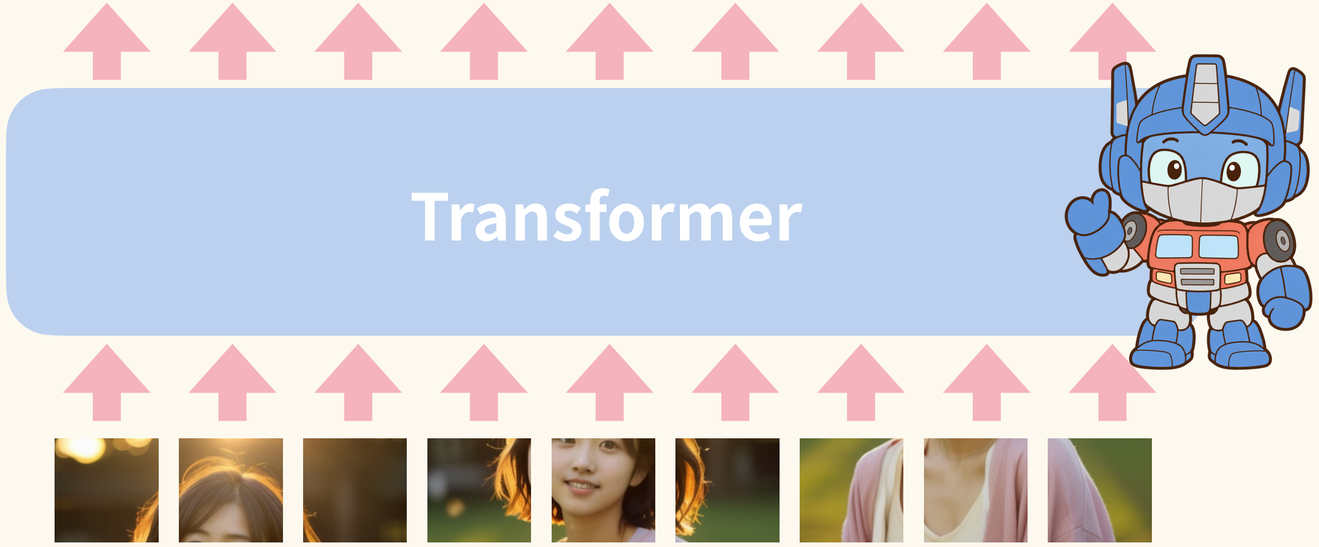

「混入」資訊也很好用

比如文字生圖的 AI, 是怎麼把文字的意思混進去的呢?

隨機產生「天馬行空」的想法。

Q

Transformer

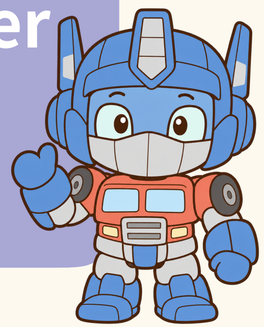

Z

混入文字的意涵。

代表文字「意思」的矩陣。

$X \rightarrow K, V$

【作業】

和 AI 討論出 Vibe Coding 程式規格書

用 Vibe Coding 做出一個互動網頁

作業

想一個有趣的應用，用 Vibe Coding 做出一個 web app，並且上傳到 GitHub 讓全世界都看得到！

① 先和 AI 討論，產生這個 App 的「規格書」。

② 用這個規格書產生一個 `index.html` 網頁。

③ 用 GitHub Page 讓全世界看到你的作品！

基本上單一檔案的 .html 檔就可以

HTML

網頁的基本語言，決定網頁的內容。

CSS

決定網頁的排版、字型、顏色。

JavaScript

讓網頁能互動，所有瀏覽器都懂的程式語言。

可以是單一檔案

還記得 Prompt 只有兩個要點

正確的資訊

它不知道你腦中的背景——把該給的資料、條件講清楚。

清楚的指引

要它做什麼、輸出成什麼樣子、給誰看，講明白。

兩個重點而已：
正確的資訊 ＋ 清楚的指引。

比如我們想寫個抽獎程式

其實就是要寫一份很好的「規格書」

「呆一布大抽獎」規格書

一、基本資訊

這是一個單一 HTML 檔（`index.html`）的抽獎轉盤，在現場用投影機播放。圖片放在同目錄的 `assets/` 資料夾，以相對路徑讀取。不需要伺服器，雙擊檔案或放上 GitHub Pages 都能使用。

二、畫面與流程

1. 名單設定：畫面一側有文字框，一行輸入一個名字或暱稱，按「確認名單」後轉盤依名單產生扇形。名單不寫死在程式裡。

2. 抽獎：按下「開始抽獎」，轉盤轉動約 5 秒、逐漸減速，停下

3. 公布得主：跳出大字的得主名字，搭配彩帶特效與中獎音效

4. 下一輪：按「繼續抽下一位」，得主自動從轉盤上移除，剩下場的人一樣視為已抽過，直接再抽下一位。

三、抽獎規則

- 名單上限 15 人，每人中獎機率相同。
- 程式先用隨機方式決定得主，再計算轉盤要停的角度，讓指針落在該格的中間附近（不會停在兩格交界、讓人看不出是誰）。
- 已抽中的人在之後的輪次中排除。

記得我們的 Prompt 必殺技

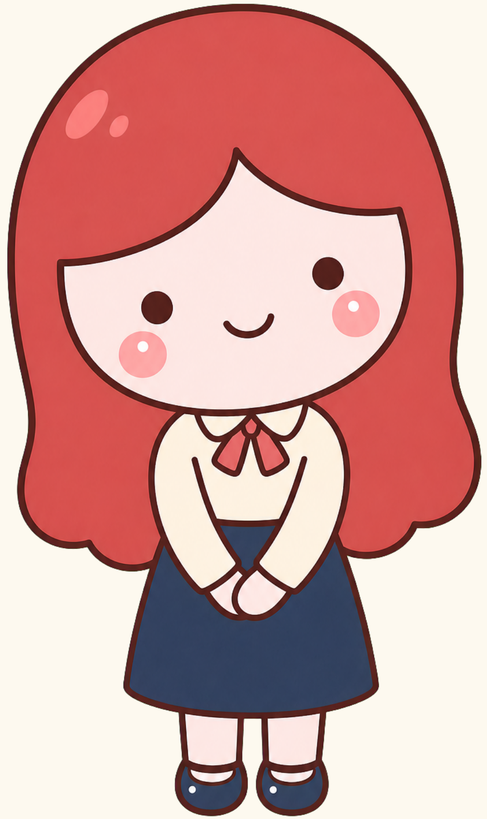

和 AI 一起寫 prompt，就是寫 prompt 的必殺技!

可以跟 AI 說

我們呆一布 AI 想辦一個小活動，最後要抽出一個獎品給幸運得主。
希望這個程式是單一的 HTML 檔，先不要寫程式，**問我一些問題，幫我把需求釐清**，或是提供一下建議。

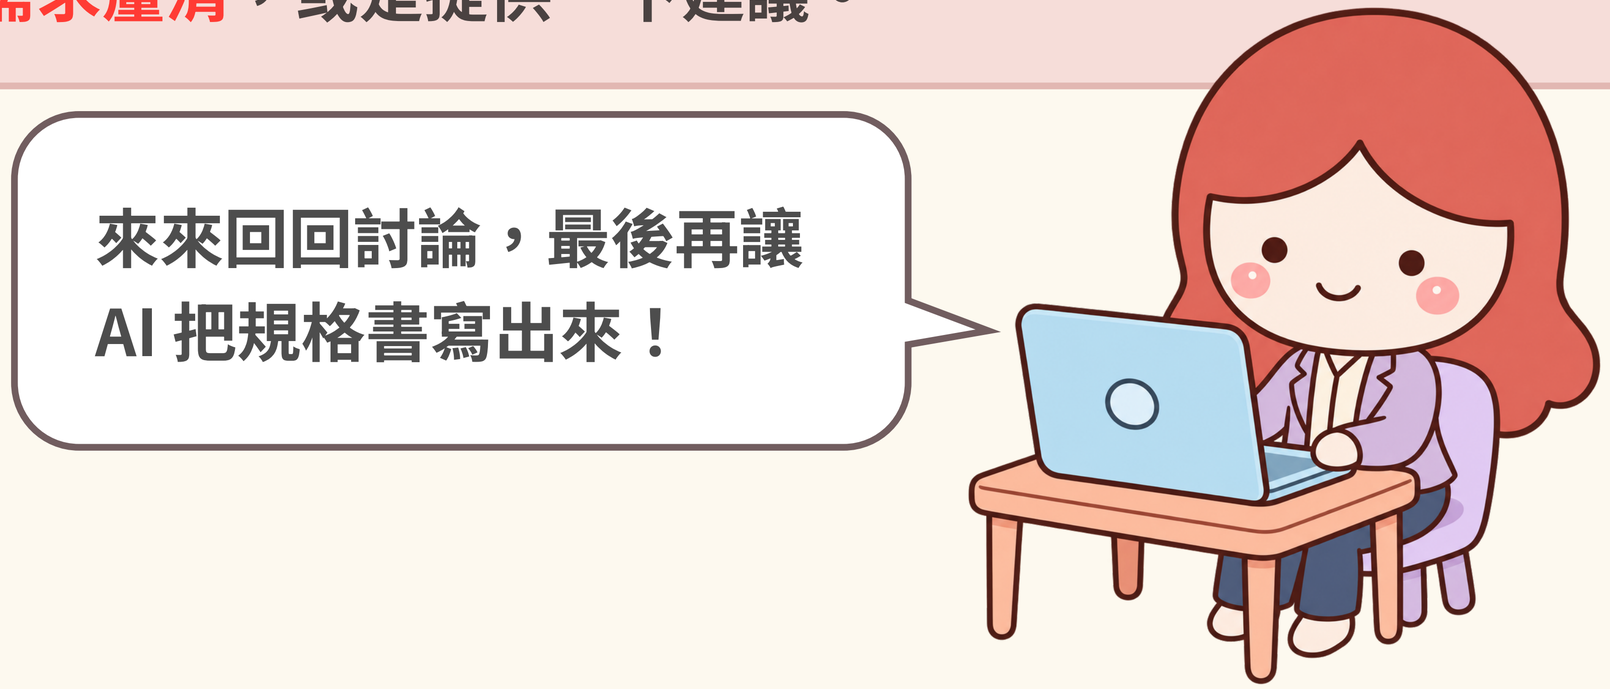

大概會是這樣子的「程式」

檔名一定要叫這個

`index.html`

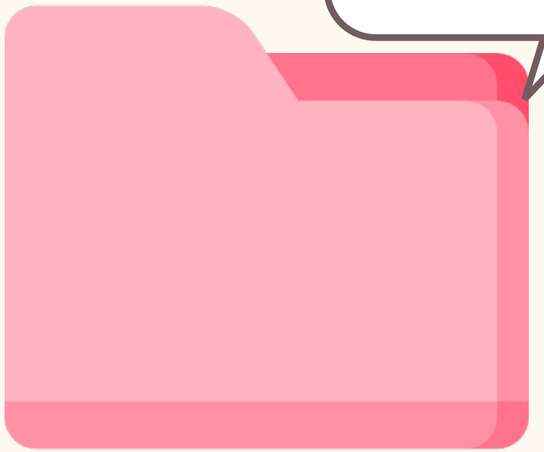

圖片可以放裡面

`assets`

把 index.html 拉到瀏覽器，就看到你的 App！

我們要放在網路上可以嗎？

當然可以，就放在 GitHub 上！

先去 `https://github.com/` 申請帳號

建立一個新的 Repo

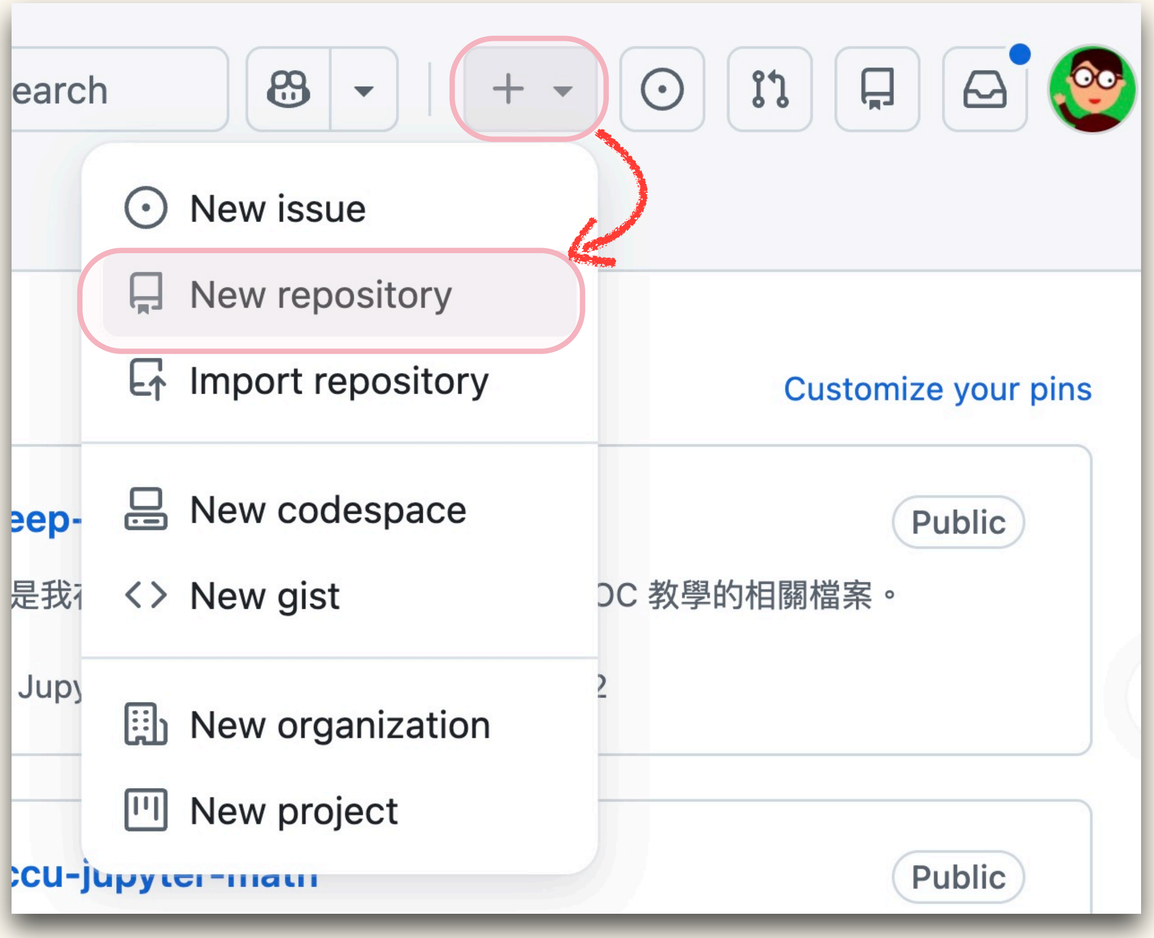
earch
New issue
New repository
Import repository
New codespace
New gist
New organization
New project
Customize your pins
Public
Public

取一個自己喜歡的名字

Create a new repository
Repositories contain a project's
ect elsewhere? Import a repository.
Required fields are marked with
取一個名字
1 General
Owner *
Repository name *
yenlung
/
vibe-tools
vibe-tools is available.
Great repository names are short and memorable. How about literate-octo-train?
Description
隨便描述一下
Vibe Coding 出來的小工具
18 / 350 characters
2 Configuration
一開始先有 README
Choose visibility *
Choose who can see and commit to this repositor
Add README
READMEs can be used as longer descriptions. About READMEs
On

從 Add file 上傳檔案

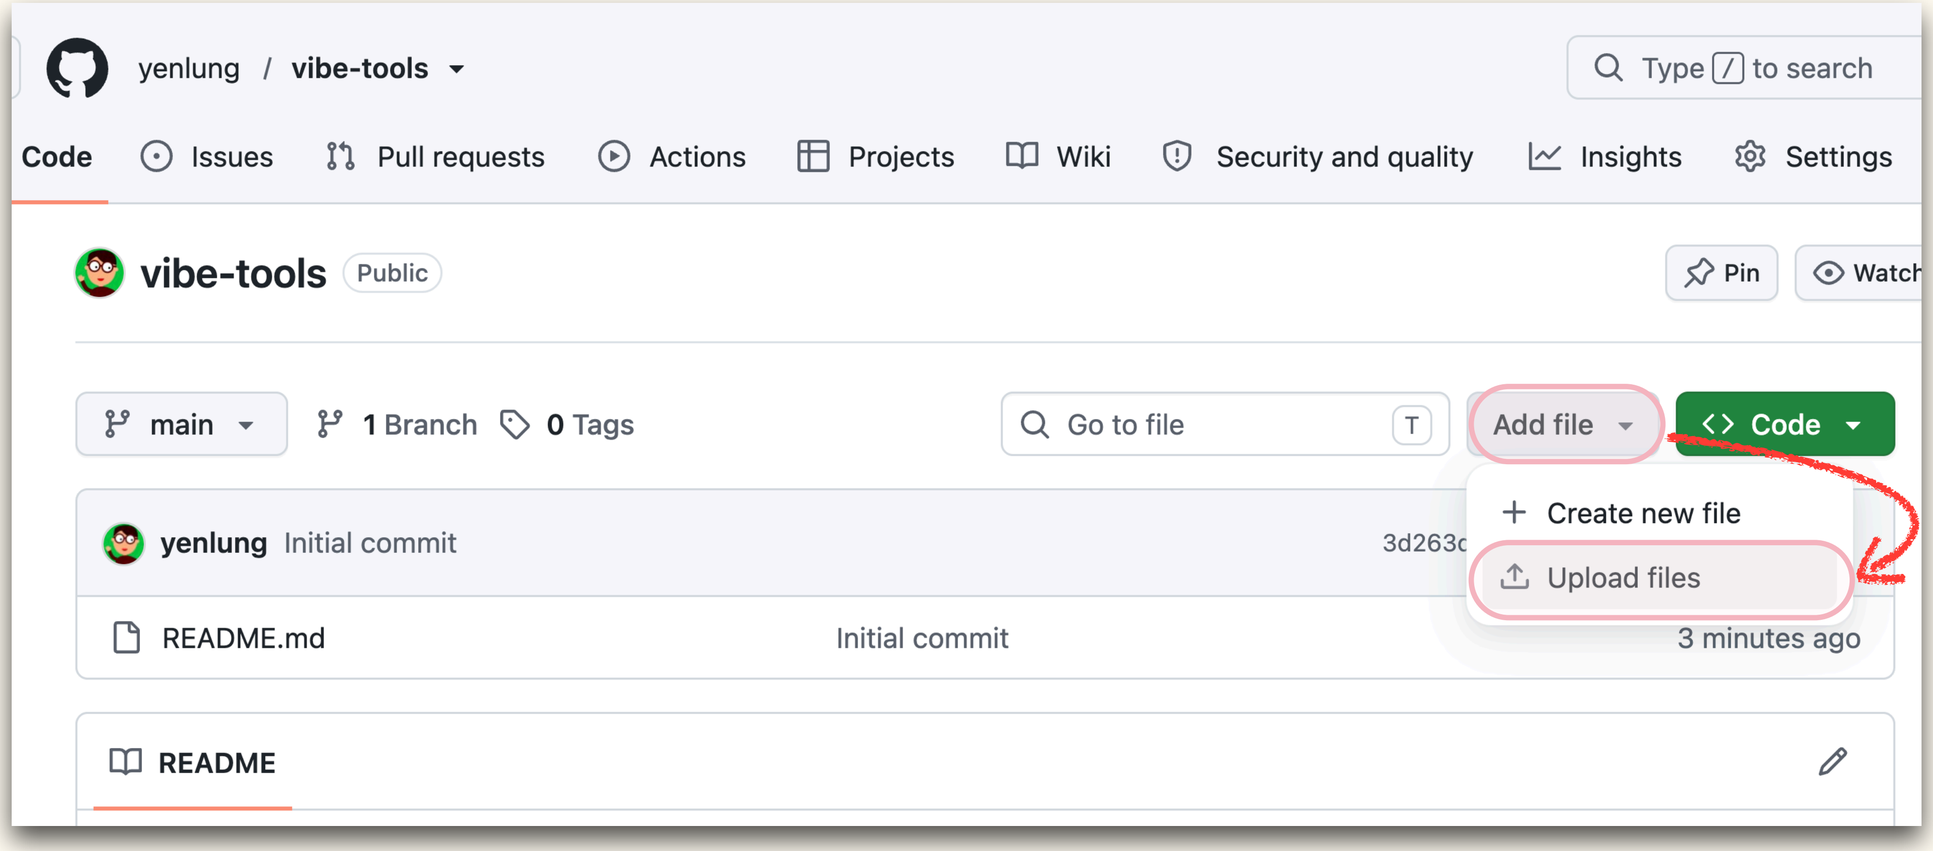

上傳你的 App

index.html

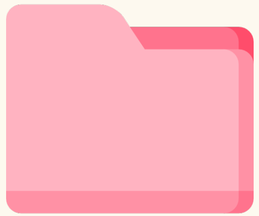

assets

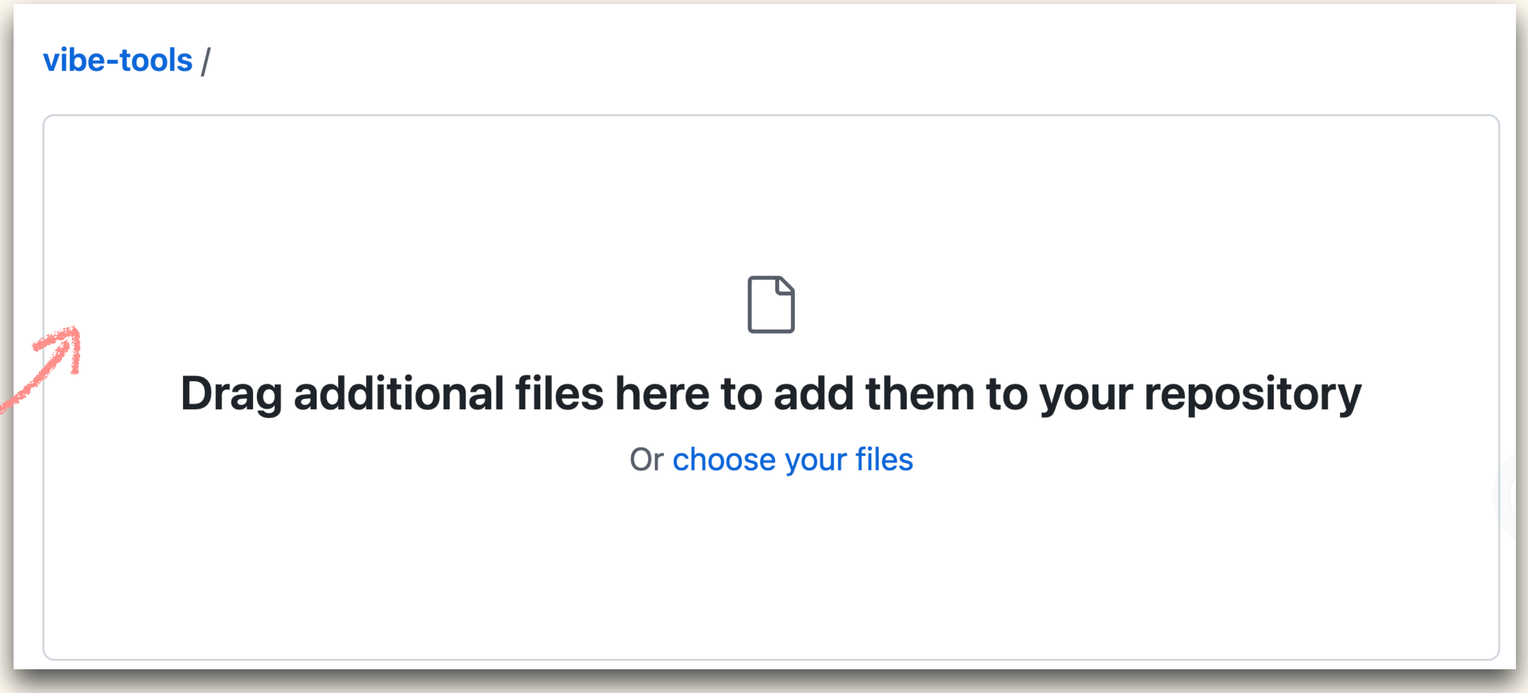

記得一定要按 **Commit**

準備用 GitHub Page 做成網頁

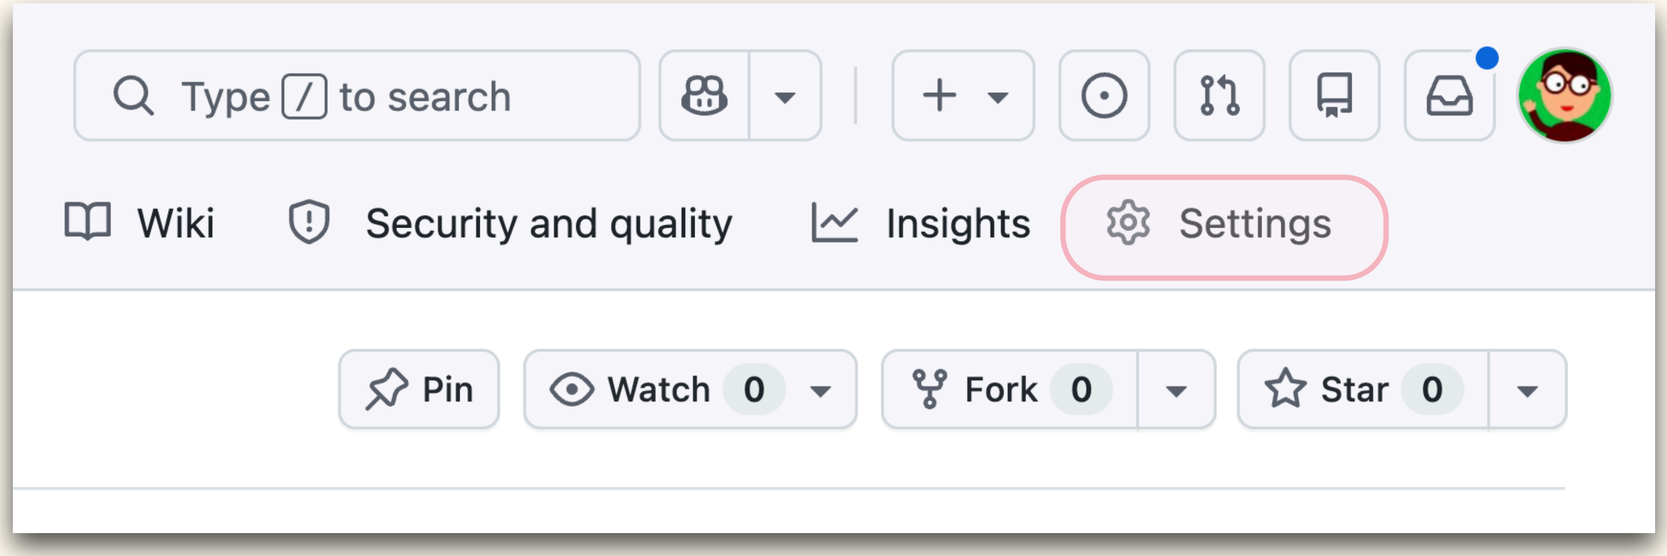

發佈你的網頁！

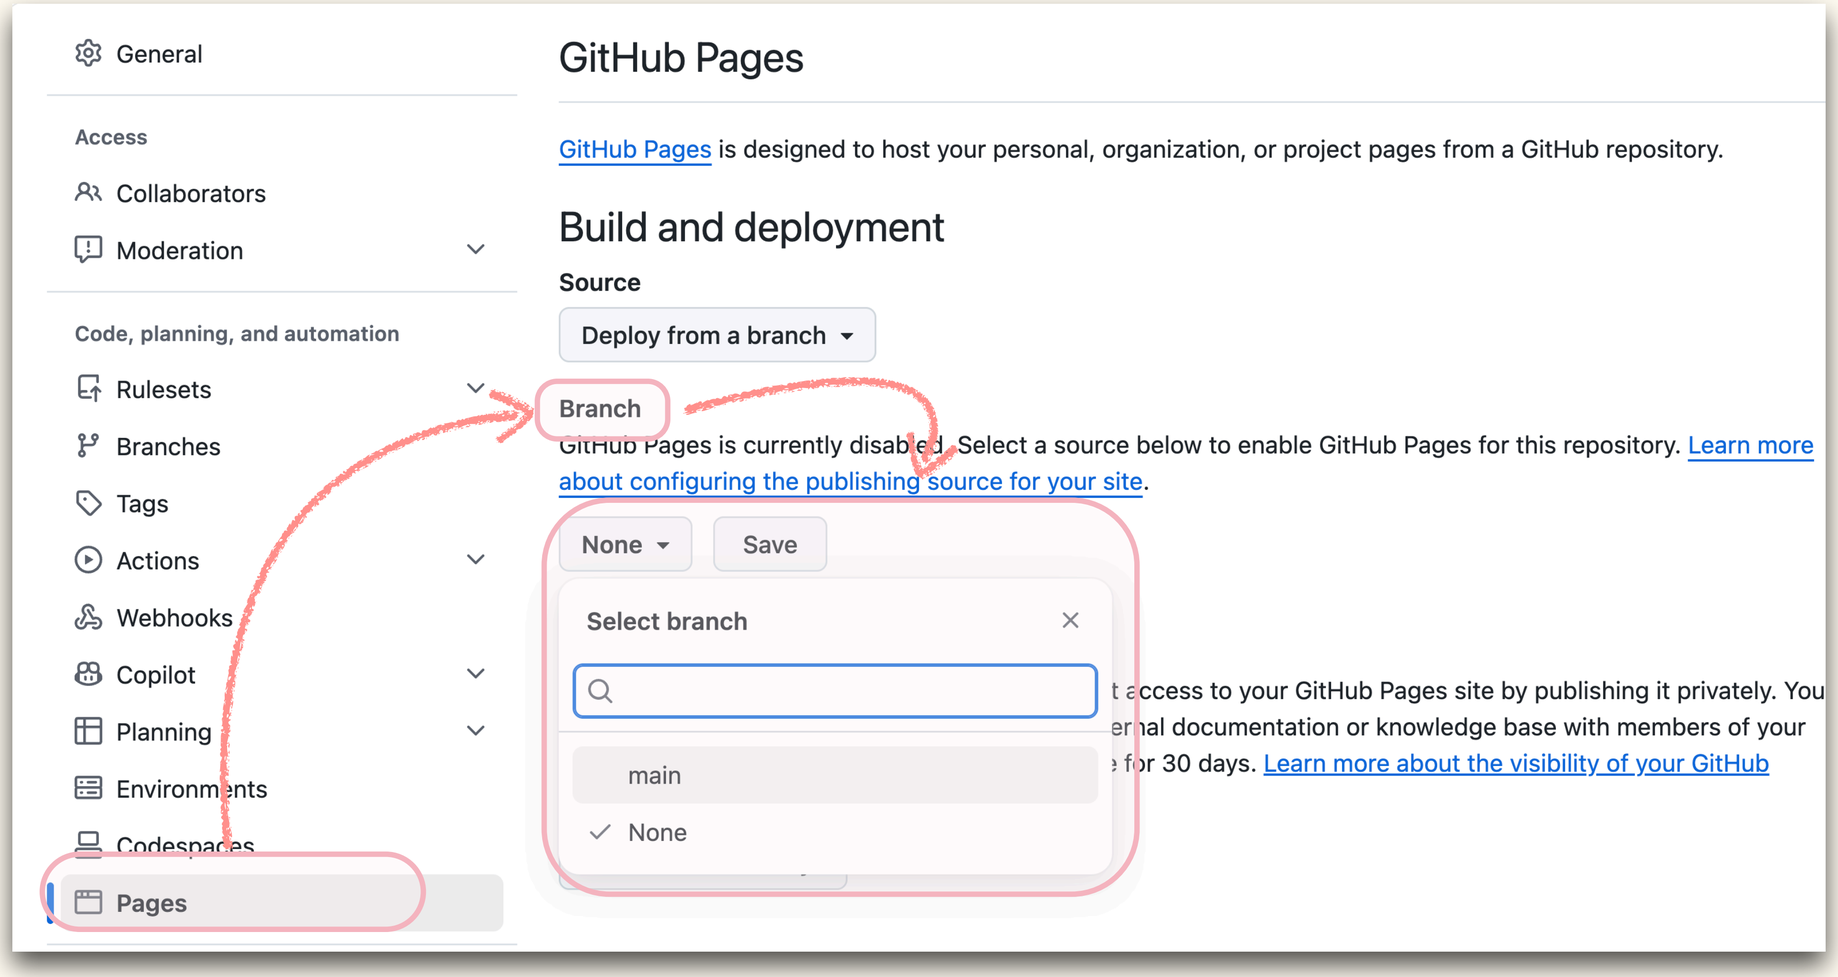
General
Access
Collaborators
Moderation
Code, planning, and automation
Rulesets
Branches
Tags
Actions
Webhooks
Copilot
Planning
Environments
Codespaces
Pages
GitHub Pages
GitHub Pages is designed to host your personal, organization, or project pages from a GitHub repository.
Build and deployment
Source
Deploy from a branch
Branch
GitHub Pages is currently disabled. Select a source below to enable GitHub Pages for this repository. Learn more about configuring the publishing source for your site.
None
Save
Select branch
main
None
access to your GitHub Pages site by publishing it privately. You
nal documentation or knowledge base with members of your
for 30 days. Learn more about the visibility of your GitHub

發佈你的大作！

用這個網址就可以
看到你的網頁！

`https://你的帳號.github.io/repo名稱/`

比如上課示範的在這裡：

`https://yenlung.github.io/vibe-tools/`

Q&A